

### 3.4 특잇값 분해

정방행렬은 고유분해로 고윳값과 고유벡터를 찾을 수 있다.

정방행렬이 아닌 행렬은 고유분해가 불가능하다. 하지만 대신 고유분해와 비슷한 특이분해를 할 수 있다.

(특잇값과 특이벡터)

$N \times M$  크기의 행렬  $A$ 를 다음과 같은 3개의 행렬의 곱으로 나타내는 것을 특이분해 (singular - decomposition) 또는 특잇값 분해 (singular value decomposition)라고 한다.

$$A = U \Sigma V^T$$

$$( \text{고유분해 } A = V \Delta V^{-1} )$$

여기에서  $U, \Sigma, V$ 는 다음 조건을 만족해야 한다.

- 대각성분이 양수인 대각방행렬이어야 한다. (큰 수부터 작은 수 순서로 배열한다.)

$$\Sigma \in \mathbb{R}^{N \times M}$$

- $U$ 는  $N$ 차원 정방행렬로, 모든 열벡터가 단위벡터이고 서로 직교해야 한다.

$$U \in \mathbb{R}^{N \times N}$$

- $V$ 는  $M$ 차원 정방행렬로, 모든 열벡터가 단위벡터이고 서로 직교해야 한다.

$$V \in \mathbb{R}^{M \times M}$$

위 조건을 만족하는 행렬  $\Sigma$ 와 대각성분들을 특잇값 (singular value), 행렬  $U$ 의 열벡터들을 왼쪽 특이벡터 (left singular vector), 행렬  $V$ 의 행벡터들을 오른쪽 특이벡터 (right singular vector)라고 부른다.

## [정리]

특이분해는 모든 행렬에 대해 가능하다.

즉, 어떤 행렬이 주어지더라도 원하는 특이분해 할 수 있다.

i) 특이분해,  $N > M$  일 때  $\rightarrow M$  개의 특이값 (대각성분)

$$A = \begin{bmatrix} u_1 & u_2 & \cdots & u_M & \cdots & u_N \end{bmatrix}_{N \times M} \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_M \\ 0 & \cdots & \cdots & 0 \\ \vdots & & & \vdots \\ 0 & \cdots & \cdots & 0 \end{bmatrix}_{N \times M} \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_M^T \end{bmatrix}_{M \times 1}$$

ii) 특이분해,  $N < M$  일 때  $\rightarrow N$  개의 특이값 (대각성분)

$$A = \begin{bmatrix} u_1 & u_2 & \cdots & u_N \end{bmatrix}_{N \times M} \begin{bmatrix} \sigma_1 & 0 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & \sigma_2 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & 0 & \sigma_3 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \sigma_N & 0 & \cdots & 0 \end{bmatrix}_{N \times M} \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_N^T \\ \vdots \\ v_M^T \end{bmatrix}_{M \times 1}$$

"주간시간표, PCA 등에서 활용"

## (특이값분해의) 축소형 reduced form

특이값 대각행렬에서 0인 부분은 사실상 이론의 필요 없기 때문에 대각행렬의 0 원소 부분과 이에 대응하는 왼쪽(혹은 오른쪽) 특이벡터들을 없애고 다음과처럼 축소된 형태로 해도 차이가 없기로 원래 행렬이 나온다.

$N \neq M$ 인 경우에는 왼쪽 특이벡터 중에서  $U_{M+1}, \dots, U_N$ 을 없앤다.

$$A = \begin{matrix} N \\ \text{---} \\ NxM \end{matrix} \quad U = \begin{matrix} N \\ \text{---} \\ NxM \end{matrix} \quad \Sigma = \begin{matrix} M \\ \text{---} \\ MxM \end{matrix} \quad V^T = \begin{matrix} M \\ \text{---} \\ MxM \end{matrix}$$

$N \neq M$ 인 경우에는 오른쪽 특이벡터 중에서  $V_{M+1}, \dots, V_N$ 을 없앤다.

$$A = \begin{matrix} M \\ \text{---} \\ NxM \end{matrix} \quad U = \begin{matrix} N \\ \text{---} \\ NxN \end{matrix} \quad \Sigma = \begin{matrix} N \\ \text{---} \\ N \times N \end{matrix} \quad V^T = \begin{matrix} M \\ \text{---} \\ N \times M \end{matrix}$$

( $\Sigma$ 이번을 사용한 특이값해)

```
from numpy.linalg import svd // U, S, V^T = svd(array)
from scipy.linalg import svd
```

\* 축소형 Parameter  
svd(A, full\_matrices=False)

singular value  $\Sigma$ ,  
대각행렬로 만든다  
np.diag(S, 1)[1:, 1:]

## 특이값과 특이벡터의 관계

행렬  $V$ 는 정규직교(orthonormal) 행렬이고,  
선형변환  $A$ 가 역행렬이다.

$$V^T = V^{-1}$$

특이분해된 행렬의 영역에  $V$ 를 곱하면,

$$AV = U\Sigma V^T V = U\Sigma$$

$$A [v_1 \ v_2 \ \dots \ v_N] = [u_1 \ u_2 \ \dots \ u_N] \begin{bmatrix} \sigma_1 & 0 & \dots \\ 0 & \sigma_2 & \dots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

행렬  $A$ 를 유한영역에 정의하면,  $M \leq N$ 인 때는

$$[Av_1 \ Av_2 \ \dots \ Av_N] = [\sigma_1 u_1 \ \sigma_2 u_2 \ \dots \ \sigma_N u_N]$$

이 되고,  $N \leq M$ 인 때는

$$[Av_1 \ Av_2 \ \dots \ Av_M] = [\sigma_1 u_1 \ \sigma_2 u_2 \ \dots \ \sigma_M u_M]$$

이 된다.

즉, 행렬  $A$ 의 특이값  $\sigma_i$ 와 특이벡터  $u_i, v_i$ 는 다음과 같은 관계를 갖다.

$Av_i = \sigma_i u_i \quad (i=1, \dots, \min(M, N))$

고유  
 $A\vec{V} = \lambda \vec{V}$

특이  
 $A\vec{U} = U\Sigma$

고유  
 $A\vec{u} = \sigma \vec{u}$

특이  
 $A\vec{u} = \sigma \vec{u}$

(특이분해와 고유분해의 관계) ✓

행렬  $A$ 의 분산행렬  $ATA$ 는

$$ATA = (V\Sigma^T U^T)(U\Sigma V^T) = V\Sigma V^T$$

가 되어, 행렬  $A$ 의 특이값  $\sigma_i$ 의 제곱 ( $\sigma_i^2$ )이 분산행렬  $ATA$ 의 고유값,  
 행렬  $A$ 의 모든 행의 특이벡터가 분산행렬  $A^T A$ 의 고유벡터가 된다.

위 식에서  $A$ 는  $N > M$ 일 때,

$$\Delta = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_M^2 \end{bmatrix}$$


$\Sigma, M > N \Rightarrow \alpha_1, \dots$

$$\Delta = \begin{bmatrix} G_1^2 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & G_2^2 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & G_N^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & \cdots & 0 \end{bmatrix}$$

$$= \text{diag}(G_1^2, G_2^2, \dots, G_N^2, 0, \dots, 0)$$

[차원축소]

\* 특이값분자를 배웠을 때 유? (Approximate) 문제 해결 위해!  
(이후 추천시스템, PCA 등 응용).




\* 1차원축소 문제.

$a_1, a_2, a_3 - PT$ 을  
(0,0) - 수직

〈점들을 어디에 풀까?〉

① 두정음제 - 페어리스처리 사용.



두정음제

$$\|x^{\perp w}\| = x^T v$$

$$(x^T \frac{v}{\|v\|})$$

$$a^2 = \|x\|^2 - (x^T v)^2$$

위의 두정음제와 동일하게 계산하면,

벡터  $w$ 와 정  $a_i$ 의 각각의 제곱은 다음과처럼 계산할 수 있다.

$$\|a_i^{\perp w}\|^2 = \|a_i\|^2 - \|a_i^{\parallel w}\|^2 = \|a_i\|^2 - (a_i^T w)^2$$

벡터  $a_1, a_2, a_3$ 을 행벡터로 가지는 행렬  $A$ 를 가정하면,

$$A = \begin{bmatrix} a_1^T \\ a_2^T \\ a_3^T \end{bmatrix}$$

행벡터의 norm의 제곱합은 행렬의 norm으로, 모든 정들의 각각의 제곱의 합은 행렬의 norm으로 계산된다.

$$\begin{aligned} \sum_{i=1}^3 \|a_i^{\perp w}\|^2 &= \sum_{i=1}^3 \|a_i\|^2 - \sum_{i=1}^3 (a_i^T w)^2 \\ &= \|A\|^2 - \|Aw\|^2 \end{aligned}$$

자기 A의 위치가 고정되어 있으므로, 행렬 A의 norm 값은 고정되어 있다.  
따라서 이 값이 가장 작아지려면  $\|Aw\|^2$ 의 값이 가장 크게 만드는  $w$ 를 찾어야 한다. 이 문제는 다음과처럼 수식으로 풀 수 있다.

$$\arg \max_w \|Aw\|^2$$

### 1차원 라

2차원 평면 위에 3개의 2차원 벡터  $a_1, a_2, a_3$  있다.

원점을 기준으로 모든 점들간 가장 먼 거리가 있는 직선을 만들고 싶다면 직선의 방향을 어떻게 해야 할까?

직선 방향을 나타내는 단위벡터를  $w$ 라고 하자.

$$w^* = \arg \max_w \|A w\|$$

단,  $\|w\|=1$

### 1차원 라의 둘이

제일 높은 행렬  $A \in \mathbb{R}^{3 \times 2}$ 를 특이분해하면 2개의 둘이값, 1개의 원족 혹은 특이벡터를 갖다. 이를 각각 다음과처럼 이용한다.

- 첫번째 둘이값:  $\sigma_1$ , 첫 번째 원족 특이벡터  $u_1 \in \mathbb{R}^3$ ,

첫 번째 원족 특이벡터  $v_1 \in \mathbb{R}^2$

- 두번째 둘이값:  $\sigma_2$ , 두 번째 원족 특이벡터  $u_2 \in \mathbb{R}^3$ ,

두 번째 원족 특이벡터  $v_2 \in \mathbb{R}^2$

- 첫번째 둘이값  $\sigma_1$ 은 두 번째 둘이값보다 큼다.

$$\sigma_1 \geq \sigma_2$$

\*  $A$ 에 오른쪽 특이벡터를 곱하면 원쪽 특이벡터 방향이 된다.

$$\begin{aligned} A v_1 &= \sigma_1 u_1 \\ A v_2 &= \sigma_2 u_2 \end{aligned}$$

스칼라

길이는 다르지만  
방향은 같음!

오른쪽 특이벡터  $v_1, v_2$ 는 직교하고 (같은 방향은 아님) 선형조합으로,  
2차원 평면의 기저벡터가 될 수 있다.

\*\*  $A$ 에 특성이 있는 2차원벡터  $w$ 는 2차원 plane의  
기저벡터가 될 수 있다  $\rightarrow$  선형조합으로 모든 2차원 공간의  
벡터를 표현할 수 있다.

우리는  $\|Aw\|$ 의 값이 최대가 되는  $w$ 를 찾어야 하는데,  
 $w$ 는 2차원 벡터이므로 2차원 평면 기저벡터인  $v_1, v_2$ 의  
선형조합으로 표현할 수 있다.

$$w = w_1 v_1 + w_2 v_2$$

$w$ 는 단위벡터으로  $w_1, w_2$ 는 다음 조건을 만족해야 한다.

$$\|w\|^2 = w_1^2 + w_2^2 = 1^2$$

이 때  $\|Aw\|$ 의 값은,

$$\|Aw\|^2 = \|A(w_1 v_1 + w_2 v_2)\|^2$$

$$= \|w, Av_1 + w_2 Av_2\|^2$$

$$\begin{aligned} (\text{제각각성}) &= \|w, \sigma_1 u_1 + w_2 \sigma_2 u_2\|^2 \rightarrow u_1, u_2 \text{ 선형조합} \\ (w^2 = a^2 b^2) &= \|w_1^2 \sigma_1^2 \|u_1\|^2 + w_2^2 \sigma_2^2 \|u_2\|^2 \text{ (orthogonal)} \end{aligned}$$

$\Rightarrow u_1, u_2$ 는 단위벡터임

$$= w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 \text{ (unit vector)}$$

$\sigma_1 > \sigma_2 > 0$   
 22/8/23  $w_1^2 + w_2^2 = 1$  이라는 제약을 만족하면서  
 $w_1\sigma_1^2 + w_2\sigma_2^2$ 를 가장 크게 하는  $w_1, w_2$ 를 구하는 문제.

$$w_1 = 1, w_2 = 0$$

즉, 첫 번째 원쪽 특이 벡터 방향으로 가중치를 놓으면 된다.

$$w = v_1$$

이때  $\|Aw\|$ 는 첫 번째 특잇값이 된다.

$$\|Aw\| = \|Av_1\| = \|\sigma_1 u_1\| = \sigma_1 \|u_1\| = \sigma_1$$

[일반적인 풀이]

만약  $N=3$ 이 아니라 일반적인 경우에는 다음과처럼 풀 수 있다.

$$\begin{aligned}
 \|Aw\|^2 &= \sum_{i=1}^N (a_i^T w)^2 \\
 &= \sum_{i=1}^N (a_i^T w)^T (a_i^T w) \\
 &= \sum_{i=1}^N w^T a_i a_i^T w \\
 &= w^T \left( \sum_{i=1}^N a_i a_i^T \right) w \\
 &= w^T A^T A w
 \end{aligned}$$

분산행렬의 고유분해 공식을 이용하면,

$$\begin{aligned} w^T A^T A w &= w^T V \Lambda V^T w \\ &= w^T \left( \sum_{i=1}^M \sigma_i^2 v_i v_i^T \right) w \quad \text{rank-1 행렬의 합} \\ &= \sum_{i=1}^M \sigma_i^2 (w^T v_i) (v_i^T w) \\ &= \sum_{i=1}^M \sigma_i^2 \|v_i^T w\|^2 \end{aligned}$$

이 식에서  $M$ 은 0이 아닌 특값임을 알 수 있다.

즉, 우리가 풀어야 할 문제는 다음과 같다.


$$\arg \max_w \|Aw\|^2 = \arg \max_w \sum_{i=1}^M \sigma_i^2 \|V_i^T w\|^2$$

이 값을 가장 크게 하려면, w를 가장 큰 특값에 대응하는 고유벡터로 만들고 해야 한다.

### Rank-1 차 문제

즉,  $a_1$ 을  $w$ 에 두개한 벡터는

$$a_1^{\parallel w} = (a_1^T w) w$$



두 개의 벡터를 원본 벡터처럼!

이제,  $w$  벡터를 이용하여  $N$ 개의  $M$ 차원 벡터  $a_1, a_2, \dots, a_N$  ( $a_i \in \mathbb{R}^M$ )을 차원으로 두개 (projection) 하여 가장 비슷한  $N$ 개의 차원 벡터  $a_1^{\parallel w}, a_2^{\parallel w}, \dots, a_N^{\parallel w}$  ( $a_i^{\parallel w} \in \mathbb{R}^M$ )을 만들 수 있다.


$$A' = \begin{bmatrix} (a_1^{nw})^T \\ (a_2^{nw})^T \\ \vdots \\ (a_N^{nw})^T \end{bmatrix} = \begin{bmatrix} a_1^T w w^T \\ a_2^T w w^T \\ \vdots \\ a_N^T w w^T \end{bmatrix} = \begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_N^T \end{bmatrix} w w^T = A_{nw}$$

이 같은 원래 행렬  $A$ 에 rank-1 행렬  $w w^T$ 를 곱해서 원래의 행렬  $A$ 에 가장 비슷한 행렬  $A'$ 를 만드는 문제이다.

$$\arg \min_w \|A - A'\| = \arg \min_w \|A - A_{nw}\| \quad \text{rank-1 matrix}$$

이러한 문제를 rank-1逼近 문제 (rank-1 approximation problem)이라고 한다.

### \* 관점의 차이



$$\textcircled{1} \quad \arg \min_w \|a_1''w\|$$

$\rightarrow \|Aw\|$  최대화

일부  
언어


②  $a_1$ 과  $a_1''w$  차

$\rightarrow \|A - A_{nw}\|$  차소화

※ 사실상

같은 문제를 같은  
같은 문제?

## K차원 구사



3차원 공간의 점들을 가장 가까운,

2차원 평면 위로 놓자

→ 2차원 구사 문제

정규직교하는  
기저 벡터가 만드는 공간

$N$ 개의  $M$ 차원 벡터  $a_1, a_2, \dots, a_N$  ( $a_i \in \mathbb{R}^M$ )를  $k$ 차원이 아니라 정규직교인 기저 벡터  $w_1, w_2, \dots, w_k$ 로 이루어진  $k$ 차원 벡터 공간으로 투영하여, 가장 비슷한  $N$ 개의  $k$ 차원 벡터  $a_1''^w, a_2''^w, \dots, a_N''^w$ 를 만들기 위한 정규직교 기저 벡터  $w_1, w_2, \dots, w_k$ 를 찾는 문제를 생각하자. 이 문제를 rank- $k$  문제라고 한다.

기저 벡터 행렬을  $W$ 라 두하자.

(단위벡터, 서로 직교.)

$$W = [w_1 \ w_2 \ \dots \ w_k] \rightarrow \text{여러 개를 채워야 함.}$$

기저 벡터들의 구성은 어떻게 하면  $\rightarrow$  어떤 각도로 잘 평면을 만들면

문제들 와 가장 가능하게 놓을 수 있나?

일반적으로  
쓰기 힘들다

\* 정규직교 기저 벡터에 대한 벡터  $a_i$ 의 투영  $a_i''^w$ 는

각 기저 벡터에 대한 내적으로 만들 수 있다.

$$a_i''^w = (a_i^T w_1) w_1 + (a_i^T w_2) w_2 + \dots + (a_i^T w_k) w_k$$

$$= \sum_{k=1}^K (a_i^T w_k) w_k$$

벡터  $a_1, a_2, \dots, a_N$  을 행벡터로 가지는 행렬  $A$  를 가장하는

$$A = \begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_N^T \end{bmatrix}$$

모든 점들간의 거리의 제곱의 합은 다음처럼 행렬의 놈으로 계산할 수 있다.

$$\sum_{i=1}^N \|a_i^{lw}\|^2 = \sum_{i=1}^N \|a_i\|^2 - \sum_{i=1}^N \|a_i^{lw}\|^2 \\ = \|A\|^2 - \sum_{i=1}^N \|a_i^{lw}\|^2$$

행렬  $A$  는 이미 주어져 있으므로, 이 값을 가장 작게 하려면 두 번째 항의 값은 가장 크게 하면 된다. 두 번째 항은  $K=1$  일 때와 같은 방법으로 분산행렬  $S$  를 배울 수 있다.

$$\sum_{i=1}^N \|a_i^{lw}\|^2 = \sum_{i=1}^N \sum_{k=1}^K \|(a_i^T w_k) w_k\|^2 \\ = \sum_{i=1}^N \sum_{k=1}^K \|a_i^T w_k\|^2 \\ = \sum_{k=1}^K w_k^T A^T A w_k$$

분산행렬의 고유분해를 사용하면

$$\sum_{k=1}^K w_k^T A^T A w_k = \sum_{k=1}^K w_k^T V \Lambda V^T w_k \\ = \sum_{k=1}^K w_k^T \left( \sum_{i=1}^M \sigma_i^2 v_i v_i^T \right) w_k \\ = \sum_{k=1}^K \sum_{i=1}^M \sigma_i^2 \|v_i^T w_k\|^2$$

이 문제도 차원 감소 문제처럼 풀면 다음과 같은 답을 얻을 수 있다.

\* 가장 큰 k개의 특이값에 대응하는 오른쪽 특이벡터가 기저벡터일 때  
가장 값이 커진다. ✓

(Ex) 3차원  $\rightarrow$  2차원 감소

$$\sigma_1^2 \|v_1\| + \sigma_2^2 \|v_2\|$$

$v_1 + v_2$  선형조합으로 표현 가능  
기약이면  $v_1 > v_2$  이고 기초선택  
(가장 큰  $\sigma_1$ )

앞 항과 똑같이  
기초를 선택하고 싶으나,  
선형독립을 청탁하게 됨.  
( $v_2$  쓸 수 없기 때문.)

$$\begin{array}{c} w_2 = v_2 \\ w_1 = v_1 \end{array}$$

가장 큰 (즉  $\sigma_1$ )  $v$ 를  
선택해서 기저를 형성하면  
"가장 가까운" 평면 공간을 얻을 수 있음.

### 랭크-k 감소 문제

우리가 찾아야 하는 것은 이 값을 가장 크게 하는 k개의 영벡터가 아닌 직교하는 단위벡터  $w_k$ 이다. 고유분해의 성질로부터 오른쪽 기저벡터 중 가장 큰 k개의 특이값에 대응하는 오른쪽 특이벡터가 우리가 찾는 기저벡터가 된다.

이 문제는 다음처럼 rank-k 감소 문제의 형태로 만들 수도 있다.

$$a_i^{\parallel w} = (a_i^T w_1) w_1 + (a_i^T w_2) w_2 + \dots + (a_i^T w_k) w_k$$

$$= [w_1 \ w_2 \ \dots \ w_k] \begin{bmatrix} a_i^T w_1 \\ a_i^T w_2 \\ \vdots \\ a_i^T w_k \end{bmatrix}$$

$$= [w_1 \ w_2 \ \dots \ w_k] \begin{bmatrix} w_1^T \\ w_2^T \\ \vdots \\ w_k^T \end{bmatrix} a_i$$

$$= W W^T a_i$$

이와 같은 행렬들을 모아놓은 행렬  $A'$ 는

$$A' = \begin{bmatrix} (a_1^{\parallel w})^T \\ (a_2^{\parallel w})^T \\ \vdots \\ (a_N^{\parallel w})^T \end{bmatrix} = \begin{bmatrix} a_1^T W W^T \\ a_2^T W W^T \\ \vdots \\ a_N^T W W^T \end{bmatrix} = \begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_N^T \end{bmatrix} W W^T$$

$$= A W W^T$$

따라서 이 문제는 원래 행렬  $A$ 에 대각 행렬  $W W^T$ 을 곱해준  
원래의 행렬  $A$ 와 가장 비슷한 행렬  $A'$ 를 만드는 문제와 같다.

$$\arg \min_{w_1, \dots, w_k} \|A - A W W^T\|$$

Recap =

고유분해

$$[A] = [V \Delta V^T]$$

(only 대칭행렬)

특이분해

$$[A] = [U \Sigma V^T]$$

$$= (\text{축소}) [U \Sigma V^T]$$

양의 정부호  
양의 준정부호  
고유값 부수 이상  
고유값 부수 이상

정방행렬  $A \in R^{N \times N}$

- $\lambda$ 는 뿐만 아니라 고유값
- $\lambda$ 는  $N$ 개
- $AV = V\Lambda$
- $\sum_{i=1}^N \lambda_i = \text{tr} A$
- $\prod_{i=1}^N \lambda_i = \det A$

대칭행렬  $A = A^T$

- $\lambda$ 는 실수
- $V^T = V^{-1}$
- $A = V\Lambda V^T$
- $A = \sum_{i=1}^N \lambda_i V_i V_i^T$   
( $i$  번 고유값)

공분산행렬  $A = X^T X$

- 모든 고유값이 0 이상 ( $\lambda_i \geq 0$ )

양의 정부호 (PD)

- $X = \text{full rank}$
- $X^{-1}$  존재
- $\lambda_i > 0$

고유분해  $Au = \lambda u$

특이분해  $Au = \sigma u$

"rank- $k$  차원제가 끝나"

$$\underset{w_1, \dots, w_k}{\arg \min} \|A - Aw\|$$