

4. 행렬의 미분

지금까지는 스칼라값을 입력으로 받아 스칼라값을 출력하는 함수를 생각했었지만
이제부터는 벡터나 행렬을 입력으로 받아서 벡터나 행렬을 출력하는 함수를 생각해보자.

"여러개의 입력을 갖는 단변수 함수" = "독립변수가 벡터인 함수"

$$f \left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \right) = f(x) = f(x_1, x_2)$$

vector $x \rightarrow$ scalar f

이를 확장하면 행렬을 입력으로 가지는 함수도 생각할 수 있다.

$$f \left(\begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix} \right) = f(X) = f(x_{11}, \dots, x_{22})$$

matrix $X \rightarrow$ scalar f

반대로 벡터나 행렬을 출력하는 함수는 여러개의 함수를 결합한 것이다.

$$f(x) = \begin{bmatrix} f_1(x) \\ f_2(x) \end{bmatrix}$$

scalar $x \rightarrow$ vector f

$$f(x) = \begin{bmatrix} f_{11}(x) & f_{12}(x) \\ f_{21}(x) & f_{22}(x) \end{bmatrix}$$

scalar $x \rightarrow \text{matrix } f$

벡터 행렬을 입력 받아 벡터 행렬을 출력할 수도 있다.

$$f(x) = \begin{bmatrix} f_1(x_1, x_2) \\ f_2(x_1, x_2) \end{bmatrix}$$

vector $x \rightarrow \text{vector } f$

$$f(x) = \begin{bmatrix} f_{11}(x_1, x_2) & f_{12}(x_1, x_2) \\ f_{21}(x_1, x_2) & f_{22}(x_1, x_2) \end{bmatrix}$$

matrix $x \rightarrow$

vector $x \rightarrow \text{matrix } f$

이러한 행렬을 일렬이나 출렬로 가지는 함수를 미분 \rightarrow 행렬 미분

- 정밀히 말해서 partial differentiation, 미분
- 행렬은 분자중심 표기법 (Numerator-layout notation) or
분모중심 표기법 (Denominator-layout notation)
두 가지가 있는데, 때로는 분모중심 표기법으로 가로

[스칼라를 벡터로 미분하는 경우.]

데이터분석에서는 항수의 출력변수가 스칼라이고 입력변수 x 가 벡터인
다면 항수를 이용하는 경우가 많다. 따라서 평미분은 $\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots$
여러개가 존재한다.

* 스칼라를 벡터로 미분하는 경우, 결과를 열벡터로 표시한다.

이렇게 만들면 벡터를 그라디언트 벡터 (gradient vector)
라고 하며, ∇f 로 표기한다.

$$\nabla f = \frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_N} \end{bmatrix}$$

(1/21)

$$f(x, y) = 2x^2 + 6xy + 7y^2 - 26x - 54y + 107$$

이제 이한 그라디언트 벡터를 구하면

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 4x + 6y - 26 \\ 6x + 14y - 54 \end{bmatrix}$$

연습문제 4.4.1

다음 함수의 2차원 벡터를 구하라.

(1) $f(x, y, z) = x + y + z$

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \\ \frac{\partial f}{\partial z} \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

(2) $f(x, y, z) = xyz$

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \\ \frac{\partial f}{\partial z} \end{bmatrix} = \begin{bmatrix} yz \\ xz \\ xy \end{bmatrix}$$



< 2차원에서의 2차원 벡터 표시 >

Quiver Plot
= Gradient vector on contour plot.

- 2개의 입력변수를 가지는 2차원 함수 $f(x, y)$
 - 평면상 컨투어 (contour) 풀꽃으로 나타낼 수 있음.
 - 입력변수 x, y 위치에서의 2차원 벡터 $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}$ 는 그 위치를 원점으로 하는 화살표로 표현할 수 있다.
 - 2차원 벡터의 방향은 편미분 성분 $\frac{\partial f}{\partial x}$ 와 $\frac{\partial f}{\partial y}$ 의 부호에 의해 결정

* 어떤 위치 x, y 에서 x 증가할 때 f 가 커질 때 $\frac{\partial f}{\partial x} > 0$, 반대의 경우라면 $\frac{\partial f}{\partial x} < 0$. 벡터는 2차원 평면에서 화살표로 나타낼 수 있으며, 가로성분이 양수이고 세로성분이 음수인 화살표는 우측 아래를 가리킬 것. →

$$z = f(x, y)$$




Gradient vector — arrow

기울기 방향을 짚어주는

기울기 방향을 짚어주는 arrow vector

is how to visualize?



커비풀에서 2차다인트 벡터가 갖는 특징

1. 2차다인트 벡터 크기는 기울기를 의미한다.
즉, 벡터의 크기가 클수록 함수곡면의 기울기가 커진다.
2. 2차다인트 벡터의 방향은 함수곡면의 기울기가 가장 큰 방향,
즉 단위 길이당 함수값 (높이)가 가장 크게 증가하는 방향을 가리킨다.
3. 2차다인트 벡터의 방향은 등고선 (isoline) 방향과 직교한다.

어떤 점 x_0 에서 다른 점 x 로 이동하면서 함수값이 얼마나 변하는지는
이미지 근사를 써서 관찰할 수 있다.

$$f(x) - f(x_0) = \Delta f \approx \nabla f(x_0)^T (x - x_0)$$

$\xrightarrow{x \rightarrow x_0, \text{ 이동하여}} \frac{\text{변한 함수값}}{\text{taylor expansion approx.}}$

변화의 방향 $x - x_0$ 가 2차다인트 벡터와 같은 방향일 때,
 Δf 가 가장 커지는 것을 알 수 있다.

등고선은 $f(x)$ 의 값이 일정한 x 의 집합이므로 다음과 같은
방정식으로 표현할 수 있다.

$$f(x) = f(x_0)$$

or

$$f(x) - f(x_0) = 0$$

같은 등고선 위의 다른 점 x_1 을 향해 움직이는 등고선 방향의 움직임은 $x_1 - x_0$ 이고,
 x_0, x_1 모두 같은 등고선 위의 점이므로 $f(x_0) = f(x_1)$ 이다. 따라서

$$\text{이미지 관계로써 } \nabla f(x_0)^T (x_1 - x_0) = f(x_1) - f(x_0) = 0$$

등고선 방향 $(x_1 - x_0)$ 과 $\nabla f(x_0)$ 이 직교를 알 수 있다.

행렬 미분법칙

수많은 matrix calculus 법칙이 존재하지만,
중급 수준을 커버하는 것은 5개 법칙으로 대부분 커버 가능

행렬 미분법칙 1: 선형 모형

선형 모형을 대변하면 고리다면트 벡터는 가중치 벡터이다.

$$f(x) = \mathbf{w}^T \mathbf{x}$$

$$\nabla f = \frac{\partial w^T x}{\partial x} = \frac{\partial x^T w}{\partial x} = w$$

(증명)

$$\frac{\partial (w^T x)}{\partial x} = \begin{bmatrix} \frac{\partial (w^T x)}{\partial x_1} \\ \frac{\partial (w^T x)}{\partial x_2} \\ \vdots \\ \frac{\partial (w^T x)}{\partial x_N} \end{bmatrix} = \begin{bmatrix} \frac{\partial (w_1 x_1 + w_2 x_2 + \dots + w_N x_N)}{\partial x_1} \\ \frac{\partial (w_1 x_1 + w_2 x_2 + \dots + w_N x_N)}{\partial x_2} \\ \vdots \\ \frac{\partial (w_1 x_1 + w_2 x_2 + \dots + w_N x_N)}{\partial x_N} \end{bmatrix}$$

$$= \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_N \end{bmatrix} = w$$

행렬 미분법칙 2: 이차 형식

이차 형식을 미분하면 행렬과 벡터의 곱으로 나타난다.

$$f(x) = x^T A x$$

$$\nabla f(x) = \frac{\partial x^T A x}{\partial x} = (A + A^T)x$$

(증명)

$$\frac{\partial (x^T A x)}{\partial x} = \begin{bmatrix} \frac{\partial (x^T A x)}{\partial x_1} \\ \frac{\partial (x^T A x)}{\partial x_2} \\ \vdots \\ \frac{\partial (x^T A x)}{\partial x_N} \end{bmatrix}$$

$$= \begin{bmatrix} \frac{\partial (\sum_{i=1}^N \sum_{j=1}^N a_{ij} x_i x_j)}{\partial x_1} \\ \frac{\partial (\sum_{i=1}^N \sum_{j=1}^N a_{ij} x_i x_j)}{\partial x_2} \\ \vdots \\ \frac{\partial (\sum_{i=1}^N \sum_{j=1}^N a_{ij} x_i x_j)}{\partial x_N} \end{bmatrix}$$

1행, 1행
 $x_1 x_1 + x_2 x_2 + \dots + x_N x_N = 0$

2행, 2행
 $x_1 x_1 + x_2 x_2 + \dots + x_N x_N = 0$

$$= \begin{bmatrix} \cancel{a_{11} x_1 x_1 + a_{12} x_1 x_2 + \dots + a_{1N} x_1 x_N} \\ \cancel{a_{21} x_2 x_1 + a_{22} x_2 x_2 + \dots + a_{2N} x_2 x_N} \\ \vdots \\ \cancel{a_{N1} x_N x_1 + a_{N2} x_N x_2 + \dots + a_{NN} x_N x_N} \end{bmatrix}$$

의미에서 생각해보면.

$$= \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \dots + a_{1N}x_N \\ a_{21}x_1 + 0 + \dots + 0 \\ a_{N1}x_1 + 0 + \dots + 0 \\ \vdots \\ 0 + a_{12}x_2 + \dots + 0 + \\ a_{21}x_1 + 2a_{22}x_2 + \dots + a_{2N}x_N + 0 \\ 0 + a_{N1}x_1 + \dots + 0 \end{bmatrix}$$

$$\left(\sum_{i=1}^N a_{1i}x_i + \sum_{i=1}^N a_{i1}x_i \right)$$

$$= \left(\sum_{i=1}^N a_{2i}x_i + \sum_{i=1}^N a_{i2}x_i \right)$$

$$\left(\sum_{i=1}^N a_{Ni}x_i + \sum_{i=1}^N a_{iN}x_i \right)$$

$$= \begin{bmatrix} \sum_{i=1}^N a_{1i}x_i \\ \sum_{i=1}^N a_{2i}x_i \\ \vdots \\ \sum_{i=1}^N a_{Ni}x_i \end{bmatrix} + \begin{bmatrix} \sum_{i=1}^N a_{i1}x_i \\ \sum_{i=1}^N a_{i2}x_i \\ \vdots \\ \sum_{i=1}^N a_{iN}x_i \end{bmatrix}$$

$$= Ax + A^T x = (A + A^T) x$$

* A의 행렬 A에 대해서 $(A+A^T)x = 2Ax$

스칼라 미분 for x

$$ax \rightarrow a$$

$$ax^2 \rightarrow 2ax$$

벡터/행렬 미분 for x

$$w^T x \rightarrow w$$

$$x^T A x \rightarrow (A + A^T)x$$

* 벡터를 스칼라로 미분하는 경우

$$\text{벡터 } f(x) = \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_M \end{bmatrix}$$

x 로

을 스칼라로 미분하는 경우, 결과를 행 벡터로 표시한다.

(gradient vector와 혼동하지 않도록!)

$$\frac{\partial f}{\partial x} = \left[\frac{\partial f_1}{\partial x} \quad \frac{\partial f_2}{\partial x} \quad \dots \quad \frac{\partial f_M}{\partial x} \right]$$

"벡터를 벡터로 미분하는 경우"

미분을 당하는 벡터의 원소가 여러개 ($i=1, 2, \dots, N$)이고,

미분을 하는 벡터 원소도 여러개 ($j=1, 2, \dots, M$)으로,

미분 결과로 나온 행렬은 $N \times M$ 행렬이 된다.

$$\frac{\partial f}{\partial x} = \left[\frac{\partial f_1}{\partial x} \quad \frac{\partial f_2}{\partial x} \quad \dots \quad \frac{\partial f_N}{\partial x} \right] = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_N} \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_2}{\partial x_1} & \dots & \frac{\partial f_N}{\partial x_1} \\ \frac{\partial f_1}{\partial x_2} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_N}{\partial x_2} \\ \vdots & \vdots & & \vdots \\ \frac{\partial f_1}{\partial x_N} & \frac{\partial f_2}{\partial x_N} & \dots & \frac{\partial f_N}{\partial x_N} \end{bmatrix}$$

행렬기본법칙 3: 행렬과 벡터의 곱의 미분

행렬 Ax 와 벡터 x 의 곱 Ax 를 벡터 x 로 미분하면 행렬 A^T 가 된다.

$$f(x) = Ax$$

$$\nabla f(x) = \frac{\partial (Ax)}{\partial x} = A^T$$

(증명)

$$Ax = c_1x_1 + c_2x_2 + \dots + c_nx_n$$

$$\frac{\partial (Ax)}{\partial x} = \begin{bmatrix} \frac{\partial (Ax)}{\partial x_1} \\ \frac{\partial (Ax)}{\partial x_2} \\ \vdots \\ \frac{\partial (Ax)}{\partial x_m} \end{bmatrix} = \begin{bmatrix} \frac{\partial (c_1x_1 + c_2x_2 + \dots + c_nx_n)^T}{\partial x_1} \\ \frac{\partial (c_1x_1 + c_2x_2 + \dots + c_nx_n)^T}{\partial x_2} \\ \vdots \\ \frac{\partial (c_1x_1 + c_2x_2 + \dots + c_nx_n)^T}{\partial x_m} \end{bmatrix}$$

$$= \begin{bmatrix} c_1^T \\ c_2^T \\ \vdots \\ c_m^T \end{bmatrix} = A^T$$

함수의 출력변수와 입력변수가 모두 벡터(다차원)인 경우에는 입력변수 각각과 출력변수 각각의 조합에 대해 모두 미분이 존재한다. 따라서 도함수는 행렬 형태가 된다. 이렇게 만들어진 도함수의 행렬을 자코비안 행렬 (Jacobian matrix)이라고 한다. 자코비안 행렬은 벡터함수를 벡터함수로 이분해서 생각하는 행렬의 전치행렬이다. 따라서 행/열의 방향이 다르다는 점에 유의한다.

$$Jf(x) = J = \left(\frac{\partial f}{\partial x} \right)^T = \begin{bmatrix} \left(\frac{\partial f_1}{\partial x} \right)^T \\ \vdots \\ \left(\frac{\partial f_n}{\partial x} \right)^T \end{bmatrix} = \begin{bmatrix} \nabla f_1^T \\ \vdots \\ \nabla f_n^T \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_N} \\ \vdots & & \vdots \\ \frac{\partial f_n}{\partial x_1} & \cdots & \frac{\partial f_n}{\partial x_N} \end{bmatrix}$$


$$J \approx \nabla$$

자코비안을 구해야 \approx 그레디언트 구해야!

대체로 함수의 2차 도함수는 그레디언트 벡터를 입력변수 벡터로 이분한 것으로, 해시안 행렬 (Hessian matrix)이라고 한다.

해시안 행렬은 그레디언트 벡터의 자코비안 행렬의 전치행렬로 정의된다.

$$Hf(x) = H = J(\nabla f(x))^T$$



$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_N} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_N} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_N \partial x_1} & \frac{\partial^2 f}{\partial x_N \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_N^2} \end{bmatrix}$$

↳ 함수가 선속이고 미분 가능한 함수라면,
해시昂 행렬은 대칭행렬이 된다.

스칼라를 행렬로 대변

출력변수 f 가 스칼라값이고 입력변수 X 가 행렬인 경우에는
도함수 행렬의 모양이 입력변수 X 와 같다.

$$\frac{\partial f}{\partial X} = \begin{bmatrix} \frac{\partial f}{\partial x_{11}} & \frac{\partial f}{\partial x_{12}} & \cdots & \frac{\partial f}{\partial x_{1N}} \\ \frac{\partial f}{\partial x_{21}} & \frac{\partial f}{\partial x_{22}} & \cdots & \frac{\partial f}{\partial x_{2N}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f}{\partial x_{M1}} & \frac{\partial f}{\partial x_{M2}} & \cdots & \frac{\partial f}{\partial x_{MN}} \end{bmatrix}$$

행렬 미분법칙 4: 행렬곱의 대각성분

두 정방행렬을 곱해서 만들어진 행렬의 대각성분 (trace)는 스칼라이다.

이 스칼라를 뒤의 행렬로 미분하면 원래 행렬의 전치행렬이 나온다.

$$f(X) = \text{tr}(WX)$$

$$W \in \mathbb{R}^{N \times N}, X \in \mathbb{R}^{N \times N}$$

$$\frac{\partial f}{\partial X} = \frac{\partial \text{tr}(WX)}{\partial X} = W^T$$

(증명)

$$\text{tr}(WX) = \sum_{i=1}^N \sum_{j=1}^N w_{ji} x_{ij}$$

$$\frac{\partial \text{tr}(WX)}{\partial x_{ij}} = w_{ji}$$

// 대응하는 항목은 $w_{ji} x_{ij}$ 단 하나밖에 없음 //

$$\frac{\partial \text{tr}(WX)}{\partial x_{ij}} = \frac{\partial \sum_{i=1}^N \sum_{j=1}^N w_{ji} x_{ij}}{\partial x_{ij}} = \frac{\partial (w_{ji} x_{ij} + \dots)}{\partial x_{ij}}$$

$$= w_{ji}$$

행렬 미분법의 5: 행렬식의 3.2

행렬식 (determinant)은 스칼라값이고, 이 값의 로그 값도 스칼라이다.
이 값을 원래의 행렬로 미분하면 원래 행렬의 역행렬의 전치 행렬이 된다.

$$f(X) = \log |X|$$

$$\frac{\partial f}{\partial X} = \frac{\partial \log |X|}{\partial X} = (X^{-1})^T$$

(증명)

행렬식의 정의에서

$$\frac{\partial}{\partial x_{i,j}} |X| = C_{i,j}$$

행렬식과 역행렬의 관계에서

$$\frac{\partial}{\partial X} |X| = C = |X|(X^{-1})^T$$

로그 함수 특성이 대입하면

$$\frac{d}{dx} \log f(x) = \frac{f'(x)}{f(x)} = \frac{|X|(X^{-1})^T}{|X|} = (X^{-1})^T$$

증명

$$w^T g \Rightarrow (w^T)^T = w$$

$$x^T A g \Rightarrow (A + AT)x$$

$$Ax \Rightarrow AT$$

$$t^T (Ax) \Rightarrow A^T$$

$$\log |X| \Rightarrow (X^{-1})^T$$

학습을 촉진하는
위한 예제

done!

functional calculus // calculus of variations

(변분법)

: input function | 복잡한 수식, functional F 출력이 계산에 들어온다.


데이터 분석에서는 함수와 더불어 다양한 범함수가 사용된다.

이 절에서는 범함수의 개념과 범함수의 미분에 해당하는 범분법을 공부한다.

* 범함수 (functional)

; 함수를 입력받아서 실수를 출력

ex) 기댓값 계산, 엔트로피 계산



(예)

알짜짜짜 대문자,
입력변수를 대괄호 (square bracket)

$$F[y(x)]$$

① 범함수 값의 계산 — (정적분)

ex. 확률변수 X의 기댓값, 엔트로피 (= 확률변수의 정적분값)

$$E[p(x)] = \int_{-\infty}^{\infty} xp(x)dx$$

$$H[p(x)] = \int_{-\infty}^{\infty} p(x) \log p(x) dx$$