

## 선형종속과 선형독립

(선형종속)

임의의 실수들로 선형결합  $\rightarrow$  영벡터

(선형독립)

임의의 실수들로 선형결합  $\rightarrow$  영벡터 X

(단,  $c_1, c_2, \dots, c_N$ 이 모두 0인 경우 제외)

"선형독립"의 수학적 표현

$$c_1x_1 + \dots + c_Nx_N = 0 \iff c_1 = \dots = c_N = 0$$

예제

다음 벡터  $x_1, x_2$ 는 선형독립이다.

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, x_2 = \begin{bmatrix} 3 \\ -3 \end{bmatrix}$$

$x_1$ 은 두 성분의 크기가 다르지만  $x_2$ 는 두 성분 크기가 같다  
 $\rightarrow$  어떤 선형결합을 시도해도 0이 나올 수 없다

예제

다음 벡터  $x_1, x_2, x_3$ 은 선형종속이다.

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, x_2 = \begin{bmatrix} 3 \\ 3 \end{bmatrix}, x_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix}$$

$$2x_1 + x_2 - x_3 = 0, \text{ 즉}$$

### 연습문제 3.2.1

다음 벡터들이 선형독립 아 prostit인지 판별하라.  
선형종속이면 영벡터를 만드는 계수값을 찾아라.

(1)

$$x_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, x_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$x_1$ 과  $x_2$ 는 A의 0 아닌 성분에 영향끼칠수 없다  
 $\rightarrow$  선형독립

(2)

$$x_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, x_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

$x_1$ 을  $x_2$  성분으로 상대할수 있다  
 $\rightarrow$  선형독립

(3)

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, x_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$$

$$2x_1 - x_2 = 0, \text{ 선형종속}$$

\* 선형독립은 차원수 = 벡터 개수를 때면 가능하다

ex. 선형독립인 2차원 벡터 3개 — 불가능

선형독립인 3차원 벡터 4개 — 불가능

## 선형독립과 선형방정식

선형방정식계를 행렬과 벡터의 집합으로 나타낼 수도 있다.

$$c_1x_1 + \dots + c_Nx_N = [x_1 \ x_2 \ \dots \ x_N] \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_N \end{bmatrix} = x_c$$

따라서 어떤 벡터들이 선형독립인지 아닌지를 알아내는 문제는 선형연립방정식을 푸는 문제와 같다.

$$x_c = 0$$


- i) 해가 only 영벡터  $\Rightarrow$  선형독립
- ii) 영벡터 아닌 해가 존재  $\Rightarrow$  선형종속
- iii) 해가 무한히 많음  $\Rightarrow$  선형종속


## 선형종속인 경우


예측모형을 만들기 위한 특징행렬  $X$ 의 열벡터들이 선형종속이거나 선형종속이 아닐 경우를 다중공선성 (multicollinearity)이라고 부른다.

→ 모델 예측성을 하락!

경우 1 벡터의 개수가 벡터의 차원보다 크면 선형종속이다.



  $m > n \rightarrow$  해 무한히 많  $\rightarrow$  선형종속

  $m \leq n \rightarrow$  대부분 선형독립  $\rightarrow$  우리가 분석할 대부분의 데이터.

[경우 2] 같은 축을 벡터가 있는지 반드시 선형종속이다.

if  $x_i = x_j$ , let  $c_j = -c_i$  and  $C_{\text{others}} = 0$

$$\begin{aligned}0 \cdot x_1 + \dots & c_i x_i + \dots c_j x_j + \dots + 0 \cdot x_N \\&= 0 \cdot x_1 + \dots c_i x_i + \dots (-c_i) x_j + \dots + 0 \cdot x_N \\&= 0\end{aligned}$$

다음처럼 중복된 항이 있을 때 선형종속이다.

$$\left[ \begin{array}{ccc} 1 & 5 & 1 \\ 3 & 6 & 3 \\ 4 & 6 & 4 \end{array} \right] \text{ OR } \left[ \begin{array}{ccc} 1 & 5 & 1-2 \\ 3 & 6 & 3 \cdot 2 \\ 4 & 6 & 4 \cdot 2 \end{array} \right]$$

\* 벡터  $x_j$  가  $x_i$ 의 실수배인 경우도 포함하지! — 으로 실수로 만들어질 수 있음

[경우 3] 어떤 벡터가 다른 벡터의 선형조합이며 반드시 선형종속이다.

$$x_1 = 2x_2 - 3x_3$$

일 때,  $c_1 = 1$ ,  $c_2 = 2$ ,  $c_3 = -3$  이면

$$-1 \cdot x_1 + 2 \cdot x_2 - 3 \cdot x_3 = 0$$

이므로 선형종속이다.


\* 아래에서 흥미하기 쉬운 실수!

- 3이, 5이, 수학 정수를 갖는 벡터의 데이터로 포함하면서,

- 위 3개 정수에 의존하는 총점수나 평균을 다시 데이터로 포함하면서,

→ 선형종속

## 랭크



$$3 = \text{RANK}$$

다른 뷰에서 볼 수가로 짹지 않을 때,  
선형독립이 가능한 최고값 (갯수)

• 랭크  $\Rightarrow$  행렬의 열벡터 중 서로 독립인 열벡터의 최대 갯수를  
열랭크 (column rank)라 한다.

$\Rightarrow$  행렬의 행벡터 중 서로 독립인 행벡터의 최대갯수를  
행랭크 (row rank)라 한다.

기호

rank A

행랭크는 행의 갯수보다 커질 수 있고,  
열랭크는 열의 갯수보다 커질 수 있으므로  
행갯수가 N이고 열의 갯수가 M인 행렬의 랭크는  
 $\min(N, M)$  보다 커질 수 없다.

$$\text{rank } A \leq \min(M, N)$$

$$A \in \mathbb{R}^{N \times M}$$

여제

다음 행렬  $X_1$ 의 두 열벡터는 선형독립이 아니거나  
열랭크는 2다.

$$X_1 = \begin{bmatrix} 1 & 3 \\ 2 & 3 \end{bmatrix}$$

(column)  $\begin{pmatrix} 1 \\ 2 \end{pmatrix} \quad \begin{pmatrix} 3 \\ 3 \end{pmatrix}$

$$\text{비율다르다} = \text{비례다} = \text{독립}$$

(row)  $(1 \ 3) \ (2 \ 3)$

$$\text{비율다르다} = \text{비례다} = \text{독립}$$

여제

다음 행렬  $X_2$ 의 세 열벡터는 선형종속이므로, 열랭크는 2보다는 작다.

그런데 이 열벡터 중 앞의 두 개는 선형독립이므로,  $X_2$ 의 랭크는 2다.

$$X_2 = \begin{bmatrix} 1 & 3 & 5 \\ 2 & 3 & 7 \end{bmatrix} \rightarrow \text{독립}$$

독립

“여제에  $X_2$ 의 랭크는

2를 초과할 수 없어!”

## \* 풀랭크

예제에서 살펴본  $X_1, X_2$ 처럼 행렬의 행의 개수와 열의 개수 중 작은 값과 같으면 풀랭크 (full rank)라고 한다.

$$\text{rank } A = \min(M, N)$$

선형독립인 벡터들을 행 또는 열로 갖는 행렬을 만들면, 정의에 의하여 항상 풀랭크다.

연습문제 3.2.4

다음 행렬의 랭크를 구하고 풀랭크인지 알아라.

(1)

$$A = \left[ \begin{array}{c|c|c|c} 1 & 5 & 6 & 15 \\ 2 & 6 & 8 & 7 \\ 3 & 11 & 14 & \\ \hline 1 & 4 & 5 & \end{array} \right]_{4 \times 3}$$

FULL RANK O/S, RANK 3으로 고려할 수 있다.

RANK = ?  
FULL RANK X

$$\therefore \left( \begin{array}{c|c} 1 & 5 \\ 2 & 6 \\ 3 & 11 \\ 1 & 4 \end{array} \right) + \left( \begin{array}{c} 6 \\ 8 \\ 14 \\ 5 \end{array} \right) = \left( \begin{array}{c} 12 \\ 14 \\ 25 \\ 9 \end{array} \right)$$

\* 두 개의 벡터의 핵심/중복 판단  $\rightarrow$  실수배 비율만 보면 OK.

\* 세 개 이상 벡터의 핵심/중복 판단  $\rightarrow$  실수배 비율 + 터치기까지 확인.

(2)

$$B = \begin{bmatrix} 1 & 8 & 6 \\ 2 & 6 & 8 \\ 3 & 11 & 14 \\ 4 & 9 & 6 \end{bmatrix}$$

↑  
독립  
↑  
독립  
↑  
독립

RANK 3  
FULL RANK

로우-랭크 행렬 - 실속행, 중복행, 정비행이다 (중복행은 제외)

$N$  차원 벡터  $x$  하나를 이용하여 만들었는 다음과 같은 행렬을  
랭크-1 행렬 (rank-1 matrix)이라고 한다.

$$xx^T = R^{N \times N}$$

이 행렬의 열벡터들은  $x$ 라고 하는 하나의 벡터를  $x_1$ 배,  $x_2$ 배, ...  $x_n$ 배한  
벡터므로 독립적인 열벡터는 1개다. 따라서 랭크-1 행렬의 랭크는 1이다.

$$\begin{aligned} xx^T &= x [x_1 \ x_2 \ \dots \ x_n] \\ &= [x_1 x \ x_2 x \ \dots \ x_n x] \end{aligned}$$

선형독립인 두 개의  $N$  차원 벡터  $x_1, x_2$ 를 이용해 만든 다음과 같은 행렬은  
랭크-2 행렬 (rank-2 matrix)이라고 한다.

$$[x_1 \ x_2] \begin{bmatrix} x_1^T \\ x_2^T \end{bmatrix} = x_1 x_1^T + x_2 x_2^T \rightarrow \text{Rank 2}$$

rank - M matrix

$$[x_1 \ x_2 \ \dots \ x_m] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} = x_1 x_1^T + x_2 x_2^T + \dots + x_m x_m^T = \sum_{i=1}^m x_i x_i^T \rightarrow M \text{ rank.}$$

연습문제 3.25

- (1) 다음 벡터로 행크-1 행렬을 만들고 NumPy로 행크를 계산하여  
실제로 1이 나오지 확인하라.

$$x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = [1] \rightarrow \text{rank 1, full-rank}$$

- (2) 다음 두 개의 벡터로 행크-2 행렬을 만들고 NumPy로 계산하여  
실제로 2가 나오지 확인하라.

$$x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, x_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 2 \\ 2 & 0 \end{bmatrix}^2.$$

rank 2, full-rank

## 랭크와 역행렬

정방행렬의 랭크와 역행렬 사이에는 다음과 같은 정리가 성립한다.

### \* [Theorem]

정방행렬 (square matrix)이 풀랭크  $\leftrightarrow$  역행렬이 존재함

정방행렬의 풀랭크가 아님  $\leftrightarrow$  역행렬이 존재하지 않음

## 벡터공간과 기저벡터

- 여러 벡터를 선형조합하면 다른 벡터를 만들 수 있다.
- 벡터  $N$ 개가 서로 선형독립이면 이 벡터들을 선형조합하여 만들수 있는 모든 벡터의 집합을 벡터공간 (vector space)  $V$ 라 하고,  
이 벡터공간의 차원을  $N$ 개라고 한다.
- 그리고 그 벡터  $N$ 개는 벡터공간의 기저벡터 (basis vector)  
라고 한다.

$$V = \{c_1x_1 + c_2x_2 + \dots + c_Nx_N \mid c_1, \dots, c_N \in \mathbb{R}^n\}$$

\* 벡터공간의 차원 (dimension)이 벡터의 차원 (길이)이 아니라,  
기저벡터의 개수로 정의된다는 점에 유의하라.

$N$ 차원 벡터  $N$ 개  $x_1, x_2, \dots, x_N$ 이 선형독립이면 이를 선형조합하여  
모든  $N$ 차원 벡터를 만들 수 있다.

(?) 독립이 아닐경우?  $\rightarrow$  못 만드는 (못 표현하는) 공간이 생긴다.

다음과 같이 증명한다. 임의의 벡터  $x$ 가 있다고 하자.

기저벡터  $x_1, x_2, \dots, x_N$ 과 이 벡터  $x$ 를 열벡터로 사용하여  
만든 행렬

$$X = [x_1, x_2, \dots, x_N, x]$$

는 크기가  $N \times (N+1)$  이므로 랭크를  $N$ 보다 줄 수 없다.

그런데  $N$ 개의 선형독립인 열벡터가 있다면 랭크는  $N$ 이며 풀랭크다.

따라서 어떠한  $N$ 차원 벡터를 생각하더라도 기저벡터의 조합으로 표현할 수 있다.

(예제)

다음 집합은 선형독립이므로 2차원 벡터공간의 기저벡터이다.

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, x_2 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

이 기저벡터  $\{x_1, x_2\}$ 를 선형조합하면 어떠한 2차원 벡터도 만들 수 있다.

(예제)

다음 벡터의 합성을 선형독립이 아님으로 벡터공간의 기저벡터가 되지 않는다.

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, x_2 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, x_3 = \begin{bmatrix} 5 \\ 7 \end{bmatrix}$$

(예제)

다음 벡터의 합성을 선형독립이므로 벡터공간의 기저벡터이다.

$$x_1 = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, x_2 = \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} \quad \{x_1, x_2\} \xrightarrow{\text{선형조합}} 2차원 V$$

$$\therefore c_1x_1 + c_2x_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \text{ 만들 수 없음}$$

~ V 차원을 벡터의 차원과  
다르게 정의하는 이유!!

### 연습문제 3.2.6

(1) 다음 기저벡터  $x_1, x_2$ 를 선형조합하여 벡터  $y_1, y_2$ 를 만드시라.

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, x_2 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$y_1 = \begin{bmatrix} 3 \\ 3 \end{bmatrix}, y_2 = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

$$\boxed{x_1 + x_2 = y_1, \quad -\frac{1}{3}x_1 - \frac{1}{3}y_1 = y_2}$$

(2) 2차원 벡터공간을 만드는 2차원 기저벡터의 또 다른 예를 들어라.

$$x_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, x_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

(3) 2차원 벡터공간을 만드는 3차원 기저벡터의 또 다른 예를 들어라.

$$x_1 = \begin{bmatrix} 1 \\ 0 \\ 4 \end{bmatrix}, x_2 = \begin{bmatrix} 0 \\ 5 \\ 7 \end{bmatrix}$$

(3) 3차원 벡터공간을 만드는 3차원 기저벡터의 또 다른 예를 들어라.

$$x_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, x_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, x_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

(definition)

정방행렬  $\rightarrow$  full rank  $\leftrightarrow$  역행렬 존재

(1) 정방행렬 full rank  $\rightarrow$  역행렬 존재.

↳ 선형독립 & 기저벡터

↳ 어떤 벡터에 대해서도 그 벡터를 만드는 선형조합 가능

↳ 다른과 같은 벡터  $e_1, e_2, \dots, e_N$ 을 만드는  $C_1, C_2, \dots, C_N$ 이 가능

$$Xc_1 = e_1 = \begin{bmatrix} 1 \\ \vdots \\ 0 \end{bmatrix}$$

$$Xc_2 = e_2 = \begin{bmatrix} 0 \\ \vdots \\ 1 \end{bmatrix}$$

위 식들을 모으면,

$$X [c_1 \ c_2 \ \dots \ c_N] = XC = I$$

정방행렬의 경우  $XC = I$ 이면  $CX = I$ 가 성립한다. (증명제 24.4)

(2) 역행렬이 존재  $\rightarrow$  full rank

"역행렬이 존재하는 경지에 다음식이 성립함을 증명"

$$X_C = 0 \Leftrightarrow C = 0$$

(i) 역행렬 존재(다양한 값이),  $C = 0 \rightarrow X_C = 0$

(ii) 역행렬이 존재하는 때  $X_C = 0$  이면,


$$X^{-1} X_C = C = 0$$

$\therefore$  역행렬 존재  $\rightarrow$  full rank.

## 벡터공간 투영

- $M$ 개의 차원  $\overset{N}{\text{차원}}$  기저벡터  $v_1, v_2, \dots, v_M$  가 존재한다고 하자.
- $M$ 은  $N$ 보다 작다.
- 이 때 모든 차차원 벡터  $x$ 에 대해 기저벡터  $v_1, v_2, \dots, v_M$ 을 선형조합하여 만든 벡터  $x''^v$  와 원래 벡터  $x$ 와의 차  $x - x''^v$ 가 모든 기저벡터와 직교하면,
- 그 벡터  $x''^v$ 를  $v_1, v_2, \dots, v_m$  벡터공간에 대하여 투영벡터라고,  
차이 벡터  $x - x''^v = x^{\perp v}$  를 벡터공간에 대한 직교벡터라고 한다.

$$(x - x''^v) \perp \{v_1, v_2, \dots, v_m\}$$



## 정규직교하는 기저벡터로 이루어진 벡터공간

길이(norm) = 1 이면서 직교

단위 기저벡터  $v_1, v_2, \dots, v_m$ 이 정규직교(orthonormal) 이면  
특이벡터  $x^{uv}$ 는 각 기저벡터에 대한 내적값으로 표현된다.

계수를 내적값으로 갖는다.

$$x^{uv} = (x^T v_1) v_1 + (x^T v_2) v_2 + \dots + (x^T v_m) v_m$$

그리고 특이벡터의 길이의 제곱은 각 기저벡터와 내적의 제곱합이다.

$$\|x^{uv}\|^2 = \sum_{i=1}^m (x^T v_i)^2$$

벡터  $x$ 에서 이 벡터  $x^{uv}$ 를 뺀 벡터  $x - x^{uv}$ , 즉 직교벡터  $x^{\perp u v}$ 가  
기저벡터  $v_1, v_2, \dots, v_m$ 에 모두 직교한다는 것은 다음처럼 증명할 수 있다.

$$\begin{aligned} v_i^T (x - x^{uv}) &= v_i^T x - v_i^T ((x^T v_1) v_1 + (x^T v_2) v_2 + \\ &\quad \dots + (x^T v_m) v_m) \\ &= v_i^T x - ((x^T v_1) v_i^T v_1 + (x^T v_2) v_i^T v_2 + \\ &\quad \dots + (x^T v_m) v_i^T v_m) \\ &= v_i^T x - x^T v_i \\ &= 0 \end{aligned}$$

이 사실로부터 벡터  $x$ 의 특이벡터  $x^{uv}$ 는 기저벡터  $v_1, v_2, \dots, v_m$ 으로 이루어진  
벡터공간의 모든 벡터 중에서 가장 벡터  $x$ 와 가까운 벡터라는 것도 알 수 있다.

기저벡터  $v_1, v_2, \dots, v_m$ 으로 이루어진 벡터공간의 어떤 벡터  $y$ , 그러면  $x^{uv}$ 와의  
차이벡터  $x^{uv} - y \leq v_1, v_2, \dots, v_m$ 으로 이루어진 벡터공간에 존재하므로

$$\begin{aligned} \text{직교벡터 } x^{\perp u v} \text{ 와 직교함. } \|x - y\|^2 &= \|x - x^{uv} + (x^{uv} - y)\|^2 \\ &= \|x^{\perp u v} + (x^{uv} - y)\|^2 \quad \text{직교끼이} \\ &= \|x^{\perp u v}\|^2 + \|(x^{uv} - y)\|^2 \quad \text{내적} = 0 \\ &\geq \|x^{\perp u v}\|^2 \end{aligned}$$

## 표준기저벡터

기저벡터 중에서도 원소 중 하나만 값이 1이고 다른 값은 0으로 이루어진 다음과 같은 기저벡터를 표준기저벡터 (standard basis vector)라고 한다.

$$e_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, e_2 = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \dots, e_N = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$$

표준기저벡터를 열로 가지는 행렬 = 항등행렬

$$[e_1 \ e_2 \ \dots \ e_N] = I_N$$

## 좌표

어떤 벡터의 좌표 (coordinate)는 기저벡터를 선형조합하여 그 벡터를 나타내기 위한 **계수벡터**를 말한다.

예를 들어, 다음처럼 기저벡터  $\{e_1, e_2\}$ 를 선형조합하여 벡터  $\alpha$ 를 나타낼 수 있다고 가정하자.

$$\alpha = x_{e_1} e_1 + x_{e_2} e_2$$

이 때 벡터  $\alpha$

$$\alpha_e = \begin{bmatrix} x_{e_1} \\ x_{e_2} \end{bmatrix}$$

을 벡터  $\alpha$ 의 기저벡터  $\{e_1, e_2\}$ 에 대한 **좌표벡터** 혹은 간단히 **좌표** (coordinate)라고 한다. 벡터와 기저벡터 그리고 좌표의 관계는 다음과 같다.

$$x = [e_1 \ e_2] \begin{bmatrix} x_{e_1} \\ x_{e_2} \end{bmatrix} = [e_1 \ e_2] x_e$$

기저벡터     
 간접벡터  
(기준)

이를 들어, 다음 기저벡터  $\{g_1, g_2\}$ 를 사용하면,

$$g_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad g_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$


위에 예로 든 벡터  $x$ 는 기저벡터  $\{g_1, g_2\}$ 를 다음과 같이 선형조합하여 표현할 수 있다.

$$x = 4g_1 + 2g_2 = [g_1 \ g_2] \begin{bmatrix} 4 \\ 2 \end{bmatrix} = [g_1 \ g_2] x_g$$

기저     
 계수/좌표

따라서 기저벡터  $\{g_1, g_2\}$ 에 대한  $x$ 의 좌표는 다음과 같다.

$$x_g = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$$



$4g_1$  만큼 가서

다시  $2g_2$  만큼 가면  $x$

$$\therefore x = [g_1 \ g_2] \begin{bmatrix} 4 \\ 2 \end{bmatrix}$$

(예제)

다음 기저벡터  $\{g_1, g_2\}$ 를 사용하면,

$$g_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, g_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

위에 예로 든 벡터  $x$ 는 기저벡터  $\{g_1, g_2\}$ 를 다음과처럼 선형조합하여 표현할 수 있다.

$$x = 4g_1 + 2g_2 = [g_1 \ g_2] \begin{bmatrix} 4 \\ 2 \end{bmatrix} = [g_1 \ g_2] x_g$$

따라서 기저벡터  $\{g_1, g_2\}$ 에 대한  $x$ 의 좌표는 다음과 같다.

$$x_g = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$$

변환행렬

$$x = x_{e1} e_1 + x_{e2} e_2 = x_{g_1} g_1 + x_{g_2} g_2$$

원래의 기저벡터가 아닌 새로운 기저벡터가 있으면 하자. 이 새로운 기저벡터들은 기존 기저벡터에 대한 좌표를 열벡터로 보고 이를 행렬로 묶은 행렬  $A$ 를 생각하자.

예를 들어, 기존의 기저벡터가  $\{e_1, e_2\}$ 이고 새로운 기저벡터  $\{g_1, g_2\}$ 가  
다음과 같은 관계가 성립한다면,

$$g_1 = \frac{1}{\sqrt{2}} e_1 + \frac{1}{\sqrt{2}} e_2$$

$$g_2 = -\frac{1}{\sqrt{2}} e_1 + \frac{1}{\sqrt{2}} e_2$$

$e_1, e_2$ 에 대한  $g_1, g_2$ 의 좌표벡터는 다음처럼 열벡터로 나타낼 수 있다.

$$g_{1e} = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}, \quad g_{2e} = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

두 좌표벡터들을 합쳐서 행렬로 표시하면 다음과 같다.

$$[g_1 \ g_2] = [e_1 \ e_2] [g_{1e} \ g_{2e}] = [e_1 \ e_2] A$$

$$A = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

이 식으로부터 다음식이 성립한다. ↳

$$\begin{cases} x_e = Ax_s \\ x_g = A^{-1}x_e = Tx_e \end{cases}$$

$$\begin{bmatrix} \text{좌표} \\ \{g_1, g_2\} \end{bmatrix} = \begin{bmatrix} T & | & \text{좌표} \\ \text{변환행렬} & | & \{e_1, e_2\} \end{bmatrix} \begin{bmatrix} \text{좌표} \\ \{e_1, e_2\} \end{bmatrix}$$

(Transformation matrix)

좌표변환이 의미하는 것

① 회전  $\rightarrow$

② Scale  $\star \cancel{\rightarrow}$

(g)을 들어, 벡터  $\alpha$ 의 표준기저벡터에 대한 차수가 다를라 같다고 하자


$$\chi = 2e_1 + 2e_2 = \begin{bmatrix} 2 \\ 2 \end{bmatrix} = \chi_e$$

표준기저벡터에 대한 새기저벡터의 차수가 다를라 같다면

$$g_{1e} = \begin{bmatrix} 1 \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}, \quad g_{2e} = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

사3<sup>rd</sup> 기저벡터에 대한 벡터  $\alpha$ 의 차는 위의 공식을 이용하여  
다음처럼 계산할 수 있다.

$$\chi_g = A^{-1} \chi_e = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}^{-1} \begin{bmatrix} 2 \\ 2 \end{bmatrix} = 1 \cdot \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 2\sqrt{2} \\ 0 \end{bmatrix}$$



$$g_1 = \frac{1}{\sqrt{2}}e_1 + \frac{1}{\sqrt{2}}e_2$$


$$g_2 = -\frac{1}{\sqrt{2}}e_1 + \frac{1}{\sqrt{2}}e_2$$

(copy)  
~~from~~  $fM = \text{sp.ndimage.affine_transform}(f, A)$

연습문제 3.2.9

다음 가변비터를 이용해 앞의 이미지를 변환하라. 변환할 이미지를 만들기  
전에 어떤 이미지가 나올지 생각해보자.

$$g_1 = \begin{bmatrix} 1 \\ 0.75 \end{bmatrix}, g_2 = \begin{bmatrix} -1 \\ 0.75 \end{bmatrix}$$



좌표변환 문제 - “결합회로밀도함수 분포시각화”

$x_1, x_2$ 간의 결합회로밀도함수

