

8.6 다변수 정규분포

D차원 다변수정규분포 (MVN: multivariate Gaussian normal distribution)의 확률밀도함수는 평균벡터 μ 와 공분산행렬 Σ 라는 두개의 변수를 가지며, 다음과 같은 수식으로 정의한다.

$$N(x; \mu, \Sigma) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right)$$

= determinant of Σ = scalar


scalar \times scalar = 확률밀도 scalar.

이 식에서 각 기호의 의미는 다음과 같다.

- $x \in \mathbb{R}^D$ 확률변수벡터
- $\mu \in \mathbb{R}^D$ 평균벡터
- $\Sigma \in \mathbb{R}^{D \times D}$ 공분산행렬

→ 양의 정수인 대칭행렬이어야 함.
따라서 역행렬이 항상 존재한다.

$$\Sigma^{-1} = \text{정밀도행렬} = \text{precision matrix} = \Lambda$$



$$N(x)$$

⇒ x 라는 벡터를 입력받는다

x 라는 벡터가 나올 확률을 출력한다.

input vector
output scalar

예제 for Σ^{-1}

다음과 같은 2차원 ($D=2$) 다변량 정규 분포를 생각하자. 2차원이고 확률변수 벡터는

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

만약 변수가 다음과 같다고 하자.

$$\mu = \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

공분산 행렬로부터 x_1 과 x_2 가 독립임을 알 수 있다. 확률밀도함수를 구하면 다음과 같다.

$$|\Sigma| = 1, \quad \Sigma^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\begin{aligned} (x - \mu)^T \Sigma^{-1} (x - \mu) &= \begin{bmatrix} x_1 - 2 & x_2 - 3 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 - 2 \\ x_2 - 3 \end{bmatrix} \\ &= (x_1 - 2)^2 + (x_2 - 3)^2 \end{aligned}$$

$$\mathcal{N}(x_1, x_2) = \frac{1}{2\pi} \exp\left(-\frac{1}{2} ((x_1 - 2)^2 + (x_2 - 3)^2)\right)$$

확률밀도함수값이 같은 등고선은 원이 된다.

$$(x_1 - 2)^2 + (x_2 - 3)^2 = r^2$$

$$\begin{aligned} p(x_1, x_2) &= e^{-(x_1 - 2)^2} e^{-(x_2 - 3)^2} \\ &= p(x_1) p(x_2) \quad (\because \text{독립}) \end{aligned}$$

scipy.stats.multivariate_normal()

mean = 평균 벡터인
cov = 공분산 행렬인

예제 2

모수가 다음과 같을 때, 공분산행렬로부터 x_1 과 x_2 가 양의 상관관계가 있다는 것을 알 수 있다.

$$\mu = \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 2 & 3 \\ 3 & 7 \end{bmatrix} = \begin{bmatrix} \sigma_{11}^2 & \sigma_{12}^2 \\ \sigma_{21}^2 & \sigma_{22}^2 \end{bmatrix}$$

이 때 확률밀도함수는 다음과 같다.


$$|\Sigma| = 5, \quad \Sigma^{-1} = \begin{bmatrix} 1.4 & -0.6 \\ -0.6 & 0.4 \end{bmatrix} \quad \text{---} \cdot \frac{\sigma_{12}}{\sqrt{\sigma_{11}\sigma_{22}}} = \rho_{12} = \frac{1}{2}$$

$$(x - \mu)^T \Sigma^{-1} (x - \mu) = \begin{bmatrix} x_1 - 2 & x_2 - 3 \end{bmatrix} \begin{bmatrix} 1.4 & -0.6 \\ -0.6 & 0.4 \end{bmatrix} \begin{bmatrix} x_1 - 2 \\ x_2 - 3 \end{bmatrix}$$

$$= \frac{7}{5} (x_1 - 2)^2 - \frac{6}{5} (x_1 - 2)(x_2 - 3) + \frac{2}{5} (x_2 - 3)^2$$

$$N(x_1, x_2) = \frac{1}{2\sqrt{5}\pi} \exp \left(-\frac{7}{5} (x_1 - 2)^2 + \frac{6}{5} (x_1 - 2)(x_2 - 3) - \frac{2}{5} (x_2 - 3)^2 \right)$$

이 확률밀도함수의 모양은 다음과 같이 회전변환된 타원 모양이 된다.



다변수 정규분포와 고윳값 분해

다변수 정규분포 = 공분산행렬 Σ 은 양의 정부호인 대칭행렬이므로 대각화가능 (diagonalize) 이다. 정밀도행렬 Σ^{-1} 은 다음처럼 분해할 수 있다.

- Λ = 고윳값행렬
- V = 고유벡터행렬

$$\Sigma^{-1} = V \Lambda^{-1} V^T$$

이를 이용하여 확률밀도함수를 다음처럼 좌표 변환 할 수 있다.

$$N(x) \propto \exp\left(-\frac{1}{2}(x-\mu)^T \underline{\Sigma^{-1}}(x-\mu)\right)$$

$$= \exp\left(-\frac{1}{2}(x-\mu)^T \underline{V \Lambda^{-1} V^T}(x-\mu)\right)$$

$$= \exp\left(-\frac{1}{2}(\boxed{V^T(x-\mu)})^T \Lambda^{-1} (\boxed{V^T(x-\mu)})\right)$$

$$= \exp\left(-\frac{1}{2}(\boxed{V^T(x-\mu)})^T \Lambda^{-1} (\boxed{V^T(x-\mu)})\right)$$

$V^T = V^{-1}$ $V^T = V^{-1}$

이 식에서

$$x' = V^{-1}(x-\mu)$$

라고 하자. 이 식은 변환행렬 V^{-1} 의 열벡터인 고유벡터를 새로운 축으로 가지도록 회전하고, μ 벡터 방향으로 평행이동하는 것을 뜻한다.

$$\begin{bmatrix} g_1 & g_2 \end{bmatrix}^{-1}$$

↑ ↗
basis vector
(기저벡터)

= transformation matrix
(변환행렬)

⇒ 이전 basis에서 새로운 basis를 나타내는 g_1, g_2 를
결국 가지는 행렬의 역행렬 V^{-1} 을 곱하면,
새로운 basis를 기준으로 다시 설명하는 것과 같다
= "좌표 변환"

최소 제곱 방법

- Λ 는 고유값 λ_i 를 대각성분으로 가지는 대각행렬이므로, 새로운 좌표 x' 에서 최솟값을 찾는 타원이 된다. 타원의 반지름은 고유값 크기에 비례한다. 반지름을 작게 하려면, 원래 좌표에서 최솟값을 찾는 μ 를 중심으로 갖고 고유값에 비례하는 반지름을 가지는 타원을 고유벡터 방향으로 회전시킨 모양이다.

$$N(x) \propto \exp\left(-\frac{1}{2} x^T \Lambda^{-1} x\right)$$

$$\propto \exp\left(\frac{x_1'^2}{\lambda_1^2} + \frac{x_2'^2}{\lambda_2^2} + \dots + \frac{x_D'^2}{\lambda_D^2}\right)$$

V 는 원래 고유벡터를 모아놓은 행렬!

$$V = \begin{bmatrix} | & | \\ v_1 & v_2 \\ | & | \end{bmatrix}$$

... 기존의 고유벡터를 새롭게 변환 (g_1, g_2) 된 이후에 basis. 축이 된다.

따라서 타원은 고유벡터 방향으로 회전한다.

<최소 제곱 방법 예제>



독립 X

x_1, x_2 좌표의 결합 최솟값

좌표 변환

x_1', x_2' 좌표의 결합 최솟값

"분리가능" 독립



$\left\{ \begin{array}{l} \text{공분산행렬의 고유값} = \text{타원의 폭} \\ \text{공분산행렬의 고유벡터} = \text{타원의 방향} \end{array} \right\}$

* Condition number = $\frac{\lambda_{\max}}{\lambda_{\min}}$

크면 다중공선성으로 판단, 나쁘다!

상관관계 (독립 X)

Scaling 문제.

다변수 정규 분포의 조건부 확률 분포

[정리] 다변수 정규 분포인 확률 변수 벡터 중, 이런 변수의 값이 주어지면 다른 확률 변수의 조건부 확률 분포는 다변수 정규 분포다.

⇒ 다변수 정규 분포 확률 밀도 함수를 지은 단면은 다변수 정규 분포가 된다.

예를 들어, 확률 변수 X 의 값 x 를 두 벡터 x_1 과 x_2 로 나누었을 때,

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

x_2 값이 주어지면 (관측되면) x_1 만의 확률 밀도 함수가 다변수 정규 분포를 이루는 것을 증명하자.

x_1 과 x_2 에 따라 기대값 벡터도 μ_1 과 μ_2 로 나뉘어진다.

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$$

공분산 행렬 Σ 도 다음처럼 나뉘어진다.

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

공분산 행렬의 역행렬인 정밀도 행렬 Λ 도 대칭이므로 분할한다.

$$\Lambda = \Sigma^{-1} = \begin{bmatrix} \Lambda_{11} & \Lambda_{12} \\ \Lambda_{21} & \Lambda_{22} \end{bmatrix}$$

이때, Σ 와 Λ 가 대칭행렬이므로 Λ_{11} 과 Λ_{22} 도 대칭행렬이고

$\Lambda_{12} = \Lambda_{21}$ 이다.

이를 적용하면

$$(x - \mu)^T \Sigma^{-1} (x - \mu) = (x_1 - \mu_{1|2})^T \Lambda_{11} (x_1 - \mu_{1|2}) + C(x_2, \mu, \Sigma)$$

가 된다. 이 식에서 조건부기댓값 $\mu_{1|2}$ 는

$$\mu_{1|2} = \mu_1 - \Lambda_{11}^{-1} \Lambda_{12} (x_2 - \mu_2)$$

이다. C 는 x_1 을 포함하지 않은 항을 가리키며 다음과 같다.

$$C = \mu_1^T \Lambda_{11} \mu_1 - 2\mu_1^T \Lambda_{12} (x_2 - \mu_2) + (x_2 - \mu_2)^T \Lambda_{22} (x_2 - \mu_2) - (x_2 - \mu_2)^T \Lambda_{12}^T \Lambda_{11}^{-1} \Lambda_{12} (x_2 - \mu_2)$$

이 식에 지수항수를 적용하면


$$p(x_1, x_2) = C' \exp((x_1 - \mu_{1|2})^T \Lambda_{11} (x_1 - \mu_{1|2}))$$

가 된다. 이 식에서 $C' = \exp C$ 이다.

즉, x_2 가 어떤 값으로 주어지면 x_1 은 조건부기댓값 $\mu_{1|2}$ 과 조건부공분산행렬 $\Sigma_{11|2}$ 를 가지는 다변수정규분포가 된다. $\Sigma_{11|2}$ 는 분할행렬의 역행렬공식으로부터 다음과 같다.

$$\Sigma_{11|2} = \Lambda_{11}^{-1} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

단면을
잘라
정규분포!



다변수 정규분포의 주변확률분포

[정리] 다변수 정규분포의 주변확률분포는 다변수 정규분포다.

즉, 결합확률밀도함수를 어떤 확률변수의 값으로 적분하여 나머지 확률변수의 주변확률분포를 구하면 다변수 정규분포다. 예를 들어, x_1 과 x_2 로 이루어진 결합 확률밀도함수 $p(x_1, x_2)$ 를 x_2 로 적분하면 x_1 의 주변확률분포는 정규분포가 된다.

$$p(x_1) = \int p(x_1, x_2) dx_2 = N(x_1, \mu_1, \Sigma_{11})$$

x_2 의 주변확률분포의 기대값은 원래 기대값 벡터 중 x_1 성분과 같고,
공분산 행렬은 분할 행렬 중 Σ_{11} 성분과 같다. (증명 생략)

하의 축으로
압축해도
정규분포!

