

## 9.3 베이지 추정법

베이지 추정법(Bayesian estimation)은 모수값이 가질 수 있는 모든 가능성의 분포를 계산하는 작업이다.

어떤 확률분포함수의 모수를  $\mu$ 라고 할 때,

— 최대가능도 추정법:  $\mu = \text{상수}$

— 베이지 추정법:  $\mu = \text{확률분포}$  (확률밀도함수를 가지는)

⇒ 어떤 값이 가능성 높고 낮은지 살펴본다는 의미

★ 베이지 추정법을 사용하는 의미/이유?

“추정된 모수값 하나만으로는 추정의 신뢰도나 신뢰구간을 구할 수 없기 때문.”

(ex) 인터넷쇼핑몰 상품 A, B에 대한 사용자 반응

• 상품 A) 전체 리뷰 3개, 좋아요 2개, 싫어함 1개

• 상품 B) 전체 리뷰 100개, 좋아요 60개, 싫어함 40개

→ 각 상품을 사용했을 때 ‘좋아요’ or ‘싫어함’이 나오는 사건은  
베르누이 분포로 모델링할 수 있다.



최대가능도 추정법에 따르면, 상품 A와 상품 B에서 ‘좋아요’가  
나온 비율을 사용하여 베르누이 모수를 구하면 다음과 같이 상품 A의  
모수가 높다.

• 상품 A의 모수  $\frac{2}{3} = 0.67$

• 상품 B의 모수  $\frac{60}{100} = 0.60$

상품 A가 상품 B보다  
평가가 좋다고 확신할 수 있을까?

⇒ 베이지 추정법 필요!



# 베이즈 추정법의 기본 원리

수학적으로 베이즈 추정법은 주어진 데이터  $\{x_1, \dots, x_n\}$ 를 기반으로 모수  $\mu$ 의 조건부 확률분포  $p(\mu | x_1, \dots, x_n)$ 를 계산하는 작업이다. 조건부 확률분포를 구해오기 위해 베이즈 정리를 사용한다.

$$p(\mu | x_1, \dots, x_n) = \frac{p(x_1, \dots, x_n | \mu) \cdot p(\mu)}{p(x_1, \dots, x_n)} \propto p(x_1, \dots, x_n | \mu) \cdot p(\mu)$$

•  $p(\mu)$  = 모수의 사전 (prior) 분포

베이즈 추정 이전에 알고 있던 모수  $\mu$ 의 분포, 모수 분포에 대해 아무런 지식이 없는 경우에는 균일 (uniform) 분포  $\text{Beta}(1, 1)$  이나, 0을 중심으로 하는 정규분포  $N(0, \sigma^2)$  등의 무정보분포 (non-informative distribution)를 사용할 수 있다. 무정보분포에 대해서는 다음 장에서 공부한다.

•  $p(\mu | x_1, \dots, x_n)$  = 모수의 사후 (posterior) 분포  
데이터  $x_1, \dots, x_n$ 이 주어진 상태에서  $\mu$ 에 대한 조건부 확률분포  
 $\Rightarrow$  우리가 베이즈 추정법으로 구하고자 하는 분포.

$p(x_1, \dots, x_n | \mu)$ 는 가능도 (likelihood) 분포  
모수  $\mu$ 가 특정한 값으로 주어졌을 때, 주어진 데이터  $\{x_1, \dots, x_n\}$ 가 나올 수 있는 확률값을 나타낸다.

이 때 계산된 분포의 분포는 두 가지 방법으로 표현한다.

## (1) 모수적 (parametric) 방법

- 다른 확률분포를 사용하여 추정된 분포의 분포를 나타낸다.
- 분포 분포를 표현하는 확률분포 함수의 모수를 하이퍼모수 (hyper-parameter) 라고 부른다.
- (모수적 방법을 사용한 베이지 추정법은 결국 하이퍼모수 값을 계산할 작업이다.)

## (2) 비모수적 (non-parametric) 방법

- 분포의 분포와 동일한 분포를 가지는 실제 표본 집합을 생성하여 히스토그램이나 치빈값 등으로 분포를 표현한다.
- (MCMC (Markov chain Monte Carlo)) 다 줄은 몬테카를로 방법이 비모수적 방법이다.

여기에서는 "모수적 방법의 몇가지 간단한 예를 살펴본다."

### 베르누이 분포 = 모수 추정

가장 단순한 이산확률변수인 베르누이 분포의 모수  $\mu$ 를 베이지 방법으로 추정해보자.  
베르누이 분포의 모수는 0부터 1 사이의 값이 되므로, 사전 분포는 하이퍼모수  $a=b=1$ 인 베타분포라고 가정하자.

$$p(\mu) \propto \mu^{a-1} (1-\mu)^{b-1} \quad (a=1, b=1) \quad \text{정보없을 때 가지는 (정보없다면 다른 값)}$$

여기서는 모두 독립적인 베르누이 분포의 묶이므로, 가능도 함수는 다음과 같다.

$$p(x_1, \dots, x_n | \mu) = \prod_{i=1}^n \mu^{x_i} (1-\mu)^{1-x_i}$$



베이스 평가를 사용하면, 사후분포가 다음과 같이 갱신된 하이퍼파라미터  $a'$ ,  $b'$  을 가지는 또다른 베타분포가 된다.

$$p(\mu | x_1, \dots, x_n) \propto p(x_1, \dots, x_n | \mu) p(\mu)$$

$$= \prod_{i=1}^N \mu^{x_i} (1-\mu)^{1-x_i} \cdot \mu^{a-1} (1-\mu)^{b-1}$$

$$= \cancel{\mu^{N_1}} \mu^{(\sum_{i=1}^N x_i) + a - 1} (1-\mu)^{(\sum_{i=1}^N (1-x_i)) + b - 1}$$

$$= \mu^{N_1 + a - 1} (1-\mu)^{N_0 + b - 1}$$


$$= \mu^{a'-1} (1-\mu)^{b'-1}$$

이렇게 사전분포와 사후분포가 모두 같은 형태를 가지는 함수 형태가 같은 확률변수로 표현될 수 있도록 해주는 사전분포를 켄레 사전 확률분포 (conjugate prior) 라고 한다.

갱신된 하이퍼파라미터는 다음과 같다.

$$a' = N_1 + a$$

$$b' = N_0 + b$$



동전을 10번 던져서 앞면 6번 (뒷면 4번)

사전분포가 하이퍼파라미터  $a=b=1$  인 베타분포라면,  
사후분포는 다음과 같은 하이퍼파라미터를 가지는 베타분포가 된다.

$$a' = 6 + 1 = 7$$

$$b' = 4 + 1 = 5$$

\* 최대가능도 추정법으로 구한 베르누이 모수의 값은 0.6

# 베이즈 추정법의 장점

"순차적 (sequential) 계산이 가능"

ex) 50개의 데이터를 매일 수집할 경우

(베이즈 추정법)

- 첫날 50개 데이터로 모수 추정
- 다음날 추가된 데이터 50개로 모수값을 더 정확하게 추정
- 계산량은 매일 동일하며 증가하지 않음

전날의 수렴확률 = 다음날의 사전확률

1일  $prior = p(\mu)$   
 $posterior = p(\mu | D_1)$

2일  $prior = p(\mu) \equiv p(\mu | D_1)$   
 $posterior = p(\mu | D_1, D_2)$

(현대적 추정법)

- 첫날 데이터 50개로 모수 추정
- 다음날 데이터 100개로 모수 추정
- 시간이 지날수록 계산량이 매일 증가함

python

```

a, b = 1, 1
print("초기 추정 : 모수 = 1")
xx = linspace(0, 1, 1000)
plt.plot(xx, sp.stats.beta(a, b).pdf(xx), ls=":", label="초기 추정")
np.random.seed(0)

```

loop 돌면서  
모수 a, b  
업데이트

```

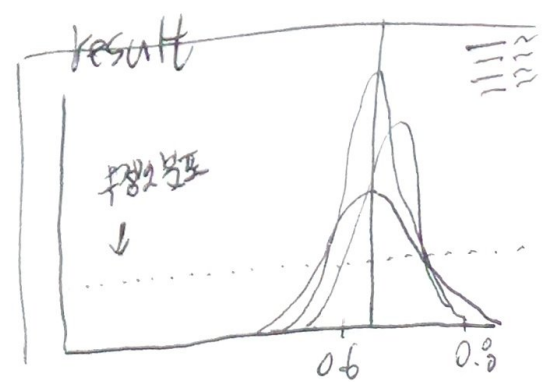
for i in range(3):
    x = sp.stats.bernoulli(mu0).rvs(50)
    n0, n1 = np.bincount(x, minlength=2)
    a, b = a + n1, b + n0
    plt.plot(xx, sp.stats.beta(a, b).pdf(xx), ls="-",
             label="{ } 차 추정".format(i))
    print("{ } 차 추정: 모수 = { }-2, { }-2".format(i, a-1, b-1))

```

```

plt.vlines(x=0.65, ymin=0, ymax=12)
plt.ylim(0, 12)
plt.legend()
plt.title("베르누이 분포의 모수를 베이즈 추정법으로 추정한 결과")
plt.show()

```



## 카테리분포의 모수 추정

"크리스 깃치가  $K$ 개의 카테리분포의 모수  $\mu$  벡터를 베이스 추정법으로 추정"

- 카테리분포의 모수의 각 원소는 모두 0보다 1이하의 값을 가지므로, 사전 분포는 하이퍼모수  $\alpha_k = 1$ 인 디리클레분포라고 가정한다.

$$p(\mu) \propto \prod_{k=1}^K \mu_k^{\alpha_k-1} \quad (\alpha_k = 1, \text{ for all } k)$$

데이터는 모두 독립적인 카테리 분포이고, 가용한 학습은 다음처럼 다항 분포다.

$$p(x_1, \dots, x_N | \mu) = \prod_{i=1}^N \prod_{k=1}^K \mu_k^{x_{i,k}}$$

베이스 정리로 사후 분포를 구하면 다음과 같이 형성된 하이퍼모수  $\alpha'_k$ 를 가지는 디리클레 분포가 된다.

$$p(\mu | x_1, \dots, x_N) \propto p(x_1, \dots, x_N | \mu) p(\mu)$$

$$= \prod_{i=1}^N \prod_{k=1}^K \mu_k^{x_{i,k}} \cdot \prod_{k=1}^K \mu_k^{\alpha_k-1}$$

$$= \prod_{k=1}^K \mu_k^{\sum_{i=1}^N x_{i,k} + \alpha_k - 1}$$

$$= \prod_{k=1}^K \mu_k^{N_k + \alpha_k - 1}$$

$$= \prod_{k=1}^K \mu_k^{\alpha'_k - 1}$$



이 경우에도 마찬가지로 디리클레 분포는 켄널 분포임을 알 수 있다.  
 갱신된 하이퍼파라미터는 다음과 같다.

$$\alpha_k' = N_k + \alpha_k$$

### 정규분포의 갱신 갯값 모수 추정

이때는 정규분포의 갯값 모수를 베이저의 방법으로 추정한다. (또한  $\sigma^2$ 은 알고있다고 가정)  
 갯값은  $-\infty$ 부터  $\infty$ 까지 모든 수가 가능하므로, 모수의 사전분포로는 정규분포를 사용한다.

$$p(\mu) = N(\mu_0, \sigma_0^2) = \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{(\mu - \mu_0)^2}{2\sigma_0^2}\right)$$

다이하든 모두 독립적인 정규분포의 곱이므로, 갯값 함수는 다음과 같다.

$$p(x_1, \dots, x_N | \mu) = \prod_{i=1}^N N(x_i | \mu) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

$$p(\mu | x_1, \dots, x_N) \propto p(x_1, \dots, x_N | \mu) p(\mu)$$

$$\propto \exp\left(-\frac{(\mu - \mu_0)^2}{2\sigma_0^2}\right)$$

베이즈 정리를 사용하여 사후 분포를 구하면, 다음과 같이 갱신된 하이퍼파라미터를 갖는 정규분포가 된다. N이 작으면 갯값 분포를 믿는다 N이 크면 갯값 분포를 믿는다

$$\mu_0' = \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 + \frac{N\sigma^2}{N\sigma_0^2 + \sigma^2} \frac{\sum x_i}{N}$$

(precision)  $\frac{1}{\sigma_0'^2} = \frac{1}{\sigma_0^2} + \frac{N}{\sigma^2}$  N (다이하든 갯값) 이 비례해서 많을수록 (precision) 이 커진다.  
다이하든 갯값 분포의 정도