

7.3 분산과 표준편차

→ 확률분포에서 확률이 얼마나 모여있는지 (퍼져있는지) 나타냄

기대값	분산
확률변수에서 어떤 값이 나올지 예측	2 예측의 확률 분포를 표현



확률변수의 분산

확률밀도함수 $p(x)$ 의 수치를 알고 있다면, 이론적인 분산을 구할 수 있다.
분산을 구하는 연산은 영어 Variance 값을 나타내며 $\text{Var}[\cdot]$ 로 표기하고,
이 연산으로 계산된 분산값은 σ^2 으로 표기한다.

$$\sigma^2 = \text{Var}[X] = E[(X - \mu)^2]$$

이산확률변수의 분산은 평균으로부터 표준편차까지 거리의 제곱을 확률밀도함수 $p(x)$ 로 가중하여 더한 값이다.

$$\sigma^2 = \sum_{x \in \Omega} (x_i - \mu)^2 p(x_i)$$

연속확률변수의 분산 \Rightarrow 평균으로부터 표준편차까지 거리의 제곱을 확률밀도함수 $p(x)$ 로 가중하여 적분한 값.

$$\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 p(x) dx$$

분산의 성질

분산은 다음과 같은 성질을 만족한다.

- 분산은 항상 0 또는 양수이다.

$$\text{Var}[X] \geq 0$$

- 특정변수가 아닌 상수값 c 에 대해 다음식이 성립한다.

$$\text{Var}[c] = 0$$

$$\text{Var}[cX] = c^2 \text{Var}[X]$$

또한 기댓값의 성질을 이용하여 다음성질을 증명할 수 있다.

$$\text{Var}[X] = E[X^2] - (E[X])^2 = E[X^2] - \mu^2$$

56

$$E[X^2] = \mu^2 + \text{Var}[X]$$

(증명)

$$\text{Var}[X] = E[(X - \mu)^2]$$

$$= E[(X^2 - 2\mu X + \mu^2)]$$

$$= E[X^2] - 2\mu E[X] + \mu^2$$

$$= E[X^2] - 2\mu^2 + \mu^2$$

$$= E[X^2] - \mu^2$$

$$= E[X^2] - (E[X])^2$$

두 확률변수의 합의 분산

두 확률변수 X, Y 의 합의 분산은 각 확률변수의 분산의 합과 다음과 같은 관계가 있다.

$$\text{Var}[X+Y] = \underbrace{\text{Var}[X]}_{\geq 0} + \underbrace{\text{Var}[Y]}_{\geq 0} + 2\underbrace{E[(X-\mu_X)(Y-\mu_Y)]}_{\text{상수 or 음수}}$$

(증명)

두 확률변수 $X+Y$ 의 기대값은 기대값의 선형결합 각 확률변수의 기대값의 합과 같다.

$$E[X+Y] = \mu_X + \mu_Y$$

분산의 정의와 기대값의 선형결합이 대우이성립한다.

$$\begin{aligned} \text{Var}[X+Y] &= E[(X+Y - (\mu_X + \mu_Y))^2] \\ &= E[((X-\mu_X) + (Y-\mu_Y))^2] \\ &= E[(X-\mu_X)^2 + (Y-\mu_Y)^2 + 2(X-\mu_X)(Y-\mu_Y)] \\ &= \text{Var}[X] + \text{Var}[Y] + 2E[(X-\mu_X)(Y-\mu_Y)] \end{aligned}$$

확률변수의 독립

두 확률변수가 서로 독립 (independent) ... 두 확률변수가 가질수 있는 모든 사건 조합에 대해서, 결합사건의 확률이 각 사건의 확률과 동일하다.
= 두 확률변수가 서로에게 영향을 미치지 않는다.

두 확률변수에서 하나의 확률변수 값이 특정 값이면 다른 확률변수의 확률분포가 영향을 받아 변하게 되면 종속 (dependent)이라고 한다.

주사위를 두번 던져 나온 합의 분포 ... 주사위 값 2개는 서로 종속.

* 확률변수 X, Y 가 서로 독립이면 다음 식이 성립한다.

$$E[(X - \mu_X)(Y - \mu_Y)] = 0$$

(증명은 추후 하함)

이 등식을 이용하면, 서로 독립인 두 확률변수의 합의 분산은 각 확률변수의 분산의 합과 같다는 것을 보일 수 있다.

$$\text{Var}[X+Y] = \text{Var}[X] + \text{Var}[Y]$$

표본평균의 분산

확률변수 X 의 표본평균 \bar{X} 도 확률변수이고, 그 기댓값 $E[\bar{X}]$ 은 원래 확률변수 X 의 기댓값 $E[X]$ 과 같다는 것을 증명한 적이 있다.

$$E[\bar{X}] = E[X]$$

표본평균 \bar{X} 의 분산 $\text{Var}[\bar{X}]$ 은 원래 확률변수 X 의 분산 $\text{Var}[X]$ 과 다음 관계를 갖는다.

$$\text{Var}[\bar{X}] = \frac{1}{N} \text{Var}[X]$$

따라서 표본평균을 계산한 표본 개수가 커지면, 표본평균의 값의 변동은 작아진다.
표본의 개수가 무한대가 되면, 표본평균의 값은 항상 일정한 값이 나온다.
즉 확률적인 값이 아니라 결정론적인 값이 된다.

(2p7)

$$\text{Var}[\bar{X}] = E[(\bar{X} - E[\bar{X}])^2]$$

$$= E[(\bar{X} - \mu)^2]$$

$$= E\left[\left(\frac{1}{N} \sum_{i=1}^N X_i - \mu\right)^2\right]$$

$$= E\left[\left(\frac{1}{N} \sum_{i=1}^N X_i - \frac{1}{N} N\mu\right)^2\right]$$

$$= E\left[\left(\frac{1}{N} \left(\sum_{i=1}^N X_i - N\mu\right)\right)^2\right]$$

* summation의 제곱

$$= E\left[\left(\frac{1}{N^2} \sum_{i=1}^N (X_i - \mu)\right)^2\right]$$

$$= E\left[\frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N (X_i - \mu)(X_j - \mu)\right]$$

$$= \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N E[(X_i - \mu)(X_j - \mu)]$$

i번째 표본값은 j번째 표본값의 영향을 받지 않으므로, X_i 와 X_j ($i \neq j$)
은 독립이다. 따라서,

$$E[(X_i - \mu)(X_j - \mu)] = 0 \quad (i \neq j)$$

따라서 실제로 이용하며 $i=j$ 인 항, 즉 제곱항만 남는다.

(정리)

$$\text{Var}[\bar{x}] = \frac{1}{N^2} \sum_{i=1}^N E[(X_i - \mu)^2]$$

$$= \frac{1}{N^2} \sum_{i=1}^N E[(X^i - \mu)^2] \quad \leftarrow E(X_i) = E(X)$$

$$= \frac{1}{N^2} \boxed{N} E[(X - \mu)^2] \quad \leftarrow \text{모두 동일한 값}$$

$$= \frac{1}{N} E[(X - \mu)^2]$$

$$= \frac{1}{N} \text{Var}[X]$$

유사도

- 데이터를 생성하는 확률변수 X 의 기대값을 구하려면, 확률밀도함수 $p(x)$ 의 수식을 알아야 한다.

- 그런데 우리는 데이터를 생성하는 확률변수 X 의 확률밀도함수 $p(x)$ 의 수식을 정확히 알지 못한다.

- 하지만 표본평균은 새 확률변수 \bar{x} 의 기대값 $E[\bar{x}]$ 는 원래 확률변수 X 의 기대값 $E[X]$ 과 같고, 표본평균 \bar{x} 는 원래 확률변수 X 의 기대값 $E[X]$ 과 비슷한 값이 나올 것이다.

(하지만 정확한 값은 아니다)

- 만약 표본 개수 N 이 크면, 표본평균 \bar{x} 의 분산이 아주 작아진다 ($\frac{1}{N}$)
표본평균의 값 \bar{x} 는 항상 표본평균의 기대값 $E[\bar{x}] = E[X]$ 근처와 거의 일정한 값이 나올 것이다.

- 따라서, 표본 개수 N 이 크면 표본평균 \bar{x} 는 원래 확률변수 X 의 기대값 $E[X]$ 의 근사값이라고 할 수 있다.

표본분산의 기대값

앞에서 표본평균의 기대값을 구하면 이론적인 평균, 즉 기대값과 같아진다는 것을 증명했다. 그런데 표본분산 S^2 의 기대값을 구하면 이론적인 분산 σ^2 과 같아지는 것이 아니라 이론적인 분산값의 $\frac{N-1}{N}$ 배가 된다.

$$E[S^2] = \frac{N-1}{N} \sigma^2$$

즉, 표본분산값이 이론적인 분산값보다 작아진다.

증명은 다음과 같다.

$$\begin{aligned} E[S^2] &= E\left[\frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2\right] = E\left[\frac{1}{N} \sum_{i=1}^N \{(X_i - \mu) - (\bar{X} - \mu)\}^2\right] \\ &= E\left[\frac{1}{N} \sum_{i=1}^N \{(X_i - \mu)^2 - 2(X_i - \mu)(\bar{X} - \mu) + (\bar{X} - \mu)^2\}\right] \\ &= E\left[\frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2\right] - 2E\left[\frac{1}{N} \sum_{i=1}^N (X_i - \mu)(\bar{X} - \mu)\right] \\ &\quad + E\left[\frac{1}{N} \sum_{i=1}^N (\bar{X} - \mu)^2\right] \end{aligned}$$

이때 첫 번째 항은,

$$\begin{aligned} E\left[\frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2\right] &= E\left[\frac{1}{N} \sum_{i=1}^N (X - \mu)^2\right] \\ &= E\left[\frac{1}{N} N (X - \mu)^2\right] \\ &= E[(X - \mu)^2] \\ &= \text{Var}[X] \\ &= \sigma^2 \end{aligned}$$

이 항을 보면,

$$\begin{aligned} E\left[\frac{1}{N} \sum_{i=1}^N (X_i - \mu)(\bar{X} - \mu)\right] &= E\left[\frac{1}{N} \sum_{i=1}^N (X_i - \mu) \left(\frac{1}{N} \sum_{j=1}^N X_j - \mu\right)\right] \\ &= E\left[\frac{1}{N} \sum_{i=1}^N (X_i - \mu) \left(\frac{1}{N} \sum_{j=1}^N (X_j - \mu)\right)\right] \\ &= E\left[\frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N (X_i - \mu)(X_j - \mu)\right] \end{aligned}$$

X_i 와 X_j ($i \neq j$)는 독립이다,

$$E[(X_i - \mu)(X_j - \mu)] = 0 \quad (i \neq j)$$

이 항을 보면

$$\begin{aligned} E\left[\frac{1}{N} \sum_{i=1}^N (X_i - \mu)(\bar{X} - \mu)\right] &= E\left[\frac{1}{N^2} \sum_{i=1}^N (X_i - \mu)^2\right] \\ &= \frac{1}{N} E\left[\frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2\right] \\ &= \frac{1}{N} E\left[\frac{1}{N} \sum_{i=1}^N (X - \mu)^2\right] \\ &= \frac{1}{N} E\left[\frac{1}{N} N (X - \mu)^2\right] \\ &= \frac{1}{N} E[(X - \mu)^2] \\ &= \frac{1}{N} \text{Var}[X] \\ &= \frac{\sigma^2}{N} \end{aligned}$$

세 번째 항은 다음과 같다.

$$\begin{aligned} E\left[\frac{1}{N} \sum_{i=1}^N (\bar{X} - \mu)^2\right] &= E\left[\frac{1}{N} \sum_{i=1}^N \left(\frac{1}{N} \sum_{j=1}^N X_j - \mu\right)^2\right] \\ &= E\left[\frac{1}{N} \sum_{i=1}^N \left(\frac{1}{N} \sum_{j=1}^N (X_j - \mu)\right)^2\right] \\ &= E\left[\frac{1}{N^3} \sum_{i=1}^N \sum_{j=1}^N \sum_{k=1}^N (X_j - \mu)(X_k - \mu)\right] \end{aligned}$$

X_j 와 X_k ($j \neq k$) 가 독립일 때,

$$E[(X_j - \mu)(X_k - \mu)] = 0 \quad (j \neq k)$$

다음 항을 보면

$$\begin{aligned} E\left[\frac{1}{N} \sum_{i=1}^N (\bar{X} - \mu)^2\right] &= E\left[\frac{1}{N^3} \sum_{i=1}^N \sum_{j=1}^N (X_j - \mu)^2\right] \\ &= E\left[\frac{1}{N^3} N \sum_{j=1}^N (X_j - \mu)^2\right] \\ &= E\left[\frac{1}{N^2} \sum_{j=1}^N (X_j - \mu)^2\right] \\ &= \frac{1}{N} E\left[\frac{1}{N} \sum_{j=1}^N (X_j - \mu)^2\right] \\ &= \frac{1}{N} \text{Var}[X] \\ &= \frac{\sigma^2}{N} \end{aligned}$$

따라서 시한의 합은 다음과 같다.

$$E[S^2] = \sigma^2 - \frac{2\sigma^2}{N} + \frac{\sigma^2}{N} = \frac{N-1}{N} \sigma^2$$

그러므로 표본분산의 기대값이 정확히 σ^2 이 되려면 편향의 자리의 계수를 $\frac{N}{N-1}$ 로 구할 때, 분모가 N 이 아닌 $N-1$ 로 써야 한다.

$$\begin{aligned} \sigma^2 &= \frac{N}{N-1} E[S^2] \\ &= \frac{N}{N-1} E\left[\frac{1}{N} \sum (X_i - \bar{x})^2\right] \\ &= E\left[\frac{1}{N-1} \sum (X_i - \bar{x})^2\right] \end{aligned}$$


따라서 기대값이 정확한 분산과 일치하는 비편향 표본분산은 다음과 같다.

$$S_{\text{unbiased}}^2 = \frac{1}{N-1} \sum (X_i - \bar{x})^2$$

* $\frac{1}{N} \sum (X_i - \bar{x})^2$ 가 실제보다 작으므로 $\frac{N}{N-1}$ 를 곱하여 크게 만들어준다.

이렇게 표본분산이 실제 분산보다 작아지는 이유는 다음과 같다.

1. 표본분산을 계산할 때 사용하는 표본평균의 값이 데이터가 많이 모여있는 쪽으로 편향되게 나온다.
2. 이렇게 데이터가 모여있는 위치에 있는 표본평균을 기준으로 각 데이터까지의 거리를 계산하면 원래의 기대값으로부터의 거리보다 작게 나올 수 있다.



비대칭도 (skewness)

비대칭도 (skewness)

- 3차 모멘트 값에서 계산함, 확률밀도함수의 비대칭 정도를 가리킨다.
- 비대칭도가 0이면 확률분포가 대칭이다.

$$E\left[\left(\frac{X-\mu}{\sigma}\right)^3\right] = \frac{\mu^3}{\sigma^3}$$

왜곡 (kurtosis)

- 4차 모멘트 값에서 계산하며, 확률이 정규분포에 대비하여 중심이 모여있는지, 바깥으로 퍼져있는지를 나타낸다.

$$E\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] = \frac{\mu^4}{\sigma^4}$$

모멘트

앞서 구한 기댓값이나 분산은 확률변수의 모멘트(moment)의 하나다.

$$\mu_n = E[(X-\mu)^n] = \int (x-\mu)^n p(x) dx$$

모멘트는 확률분포에서 계산한 특징값이다. 만약 두 확률변수 X, Y 가 있고
처부터 무한 대까지 모든 모멘트값이 서로 같다면
두 확률변수는 같은 확률분포다.

$$E[X] = E[Y]$$

$$E[(X-\mu_X)^2] = E[(Y-\mu_Y)^2]$$

$$E[(X-\mu_X)^3] = E[(Y-\mu_Y)^3]$$

$$X \stackrel{d}{=} Y \quad (d = \text{같은 확률분포})$$