

## 7.6 조건부 기댓값과 여측문제

확률변수  $Y$ 의 기댓값을 구할 때 주변 확률밀도함수  $P_Y(y)$ 를 사용하여  
가중치를 계산하지 않고 조건부 확률밀도함수  $P_{Y|X}(y|x)$ 를 이용하여 가중치를  
계산하면 조건부 기댓값 (conditional expectation) 혹은 조건부 평균 (conditional mean)  
이 된다.

$$E_Y[Y|X] = \int_{y=-\infty}^{y=\infty} y P_{Y|X}(y|x) dy$$

또는 간단히 다음처럼 쓴다.

$$E[Y|X] = \int y p(y|x) dy$$

또는 간단히 다음처럼 쓴다.


$$E[Y|X] = \int y p(y|x) dy$$

조건부 기댓값에서 조건이 되는 확률변수  $X$ 의 값  $x$ 은 조건부 기댓값을 사용하는 사용자와  
지정해야 하는 독립변수이다.

따라서 조건부 기댓값은 조건이 되는 확률변수의 값이 바뀌어 값이 달라지는  
확률변수이다. 또한  $E[Y|X]$ 는 조건이 되는 확률변수  $X$ 의 값  $x$ 을 입력으로  
갖는 함수다.

user input

$$E[Y|X=x] = f(x)$$



$x$ 에 따라 결정되는  $f(x) = E[Y|X=x]$

=  $x$ 에 따라 결정되는 확률분포의 중심값, 중심위치.

= 조건부 기대값

\*  $E[Y] =$  결정론적, 상수  $= \int y P(y) dy$

\*  $E[Y|X] =$   $x$ 에 따라 결정 확률변수  $= \int y P(y|x) dy$

$x$ 의 결정론적 숫자

$f(x) \dots x$ 의 확률변수 ( $X$ 의 변화)

$\uparrow$   
확률변수  $X$ 의 출력값

$f(X) \dots$  "확률변수의 변화"



# 예측문제

두 확률변수  $X, Y$ 에서  $X$ 값을 알고 있을 때  $Y$ 값을 추정하기

= 예측 (prediction)

- $Y$ 가 연속 확률변수  $\rightarrow$  regression analysis
- $Y$ 가 이산 확률변수  $\rightarrow$  classification

일반적으로 조건부기댓값 = 예측값의 합 =  $\hat{y}$   
(때에 따라 리만값, 중앙값)

$$x \xrightarrow{\text{prediction}} \hat{y} = E[Y|X] = f(x)$$

## 조건부기댓값의 성질

조건부기댓값  $E[Y|X]$ 가  $X$ 의 함수 (=변환, transformation) 이므로,  
조건부기댓값  $E[Y|X]$ 도 확률변수다.

(if) 확률변수  $Y$ 가 확률변수  $X$  값을 독립변수로 하는 결정론적 함수값이라면

$$Y = g(X)$$

성치가  $X$ 의 값을 어떤  $x$ 로 정하면  $Y$ 가 결정되므로  $Y = g(x)$ 는 상수가 된다.

$$E[Y|X] = E[g(X)|X] = g(X)$$

같은 방식으로, 확률변수  $X$ 와  $Y$ 가 결정론적 함수관계가 아닐 때도 다음등식이 성립한다.

$$E[g(X)Y|X] = g(X)E[Y|X]$$

(사실)

## 전체 기대값의 성질

조건부 기대값은 확률변수이므로 조건이 되는 확률변수에 대해 다시 기대값을 구할 수 있다.  
이렇게 반복하여 구한 조건부 기대값의 기대값은 원래 확률변수의 기대값과 같다.

$$E_X[E_Y[Y|X]] = E_Y[Y]$$

확률변수

간단히 다음처럼 쓰기도 한다.

$$E[E[Y|X]] = E[Y]$$

이를 전체 기대값의 법칙 (law of total expectation) 또는  
반복 기대값의 법칙 (law of iterated expectation) 이라고 한다.

$X, Y$ 가 이산확률변수인 경우에는 다음처럼 증명할 수 있다.

$$\begin{aligned} E_X[E_Y[X|Y]] &= \sum_{x_i \in X} p(x_i) E_Y[X|Y] \\ &= \sum_{x_i \in X} p(x_i) \sum_{y_j \in Y} p(y_j|x_i) y_j \end{aligned}$$

전체 확률의  
법칙.

$$\begin{aligned} &= \sum_{x_i \in X} \sum_{y_j \in Y} p(x_i) p(y_j|x_i) y_j \\ &= \sum_{x_i \in X} \sum_{y_j \in Y} p(x_i, y_j) y_j \\ &= \sum_{y_j \in Y} p(y_j) y_j \\ &= E_Y[Y] \end{aligned}$$




## 조건부 분산

조건부 기대값을 정의한 것처럼 조건부 분산 (conditional variance)도  
다음처럼 정의할 수 있다.

$$\begin{aligned} \text{Var}_Y[Y|X] &= E_Y[(Y - E_Y[Y|X])^2 | X] \\ &= \int (Y - E_Y[Y|X])^2 f_{Y|X}(y|x) dy \end{aligned}$$

조건부 분산은  $x$  값을 알고 있을 때 이에 대한 조건부 확률 분포  $p(y|x)$ 의 분산이다.  
여러 가지의 관점으로 보면 조건부 분산은 예측의 불확실성, 즉 예측으로 맞출 수 없는  
범위를 뜻한다.



## 전체 분산의 법칙

확률변수의 분산은 조건부 분산의 기대값과 조건부 기대값의 분산의 합과 같다.  
이를 전체 분산의 법칙 (law of total variance) 이라고 한다.

$$\boxed{\text{Var}[Y]} = \underbrace{E[\text{Var}[Y|X]]}_{\text{조건부 분산의 기대값}} + \underbrace{\text{Var}[E[Y|X]]}_{\text{조건부 기대값의 분산}}$$

(회귀분석에서 내놓은 예측치의 평균)      (회귀분석에서 내놓은 예측치의 변동성)

① 회귀분석에서  
나눠줄 수 있는 예측치  
평균  
② 회귀분석 예측치의 변동성

(증명)

- 전체 가측값의 법칙을 사용.

$$\begin{aligned}\text{Var}[Y] &= E[Y^2] - (E[Y])^2 \\&= E[E[Y^2|X]] - (E[E[Y|X]])^2 \\&= E[\text{Var}[Y|X] + (E[Y|X])^2 - (E[E[Y|X]])^2] \\&= E[\text{Var}[Y|X]] + (E[E[Y|X]^2] - (E[E[Y|X]])^2) \\&= E[\text{Var}[Y|X]] + \text{Var}[E[Y|X]]\end{aligned}$$

$E[Y|X] = \hat{y}$ 로 표현하면,

$$\text{Var}[Y] = E[(\hat{y} - y)^2] + \text{Var}[\hat{y}]$$

★ Takeaways

- 예측문제의 관점에서, 조건의 가측값  $E[(\hat{y} - y)^2]$ 은 예측 오차, 즉 편향 (bias)의 평균적인 크기를 뜻한다.
- 조건의 가측값의 분산  $\text{Var}[\hat{y}]$ 은 예측값의 변동 크기다.
- 예측값의 변동 크기가 증가한다 = 예측값이 복잡하고 비선형적이며, 주어진 데이터에 과적화되기 쉽다

따라서,

- (1) 예측 오차의 크기나 예측값 변동량이 일정하므로, 예측 오차를 줄이면 모형이 복잡해지고 과적화가 되며
  - (2) 반대로 모형 과적화를 막기 위해 단순히 하면 예측 오차 증가
- ⇒ 편향-분산 상충 (Bias-variance Tradeoff)