

Week 3. 데이터의 분류

3.1 데이터의 유사도

- 인공지능이 데이터로 수행하는 주요기능 1) 판단 (decision), 2) 예측 (prediction)
- 주어진 데이터의 특징에 따라 데이터가 어느 범주 (class or category)에 속하는지 판단하는 것 = 분류 (classification)

→ 데이터를 분류하기 위해서:

① 데이터를 제반할 수 있는 형태로 표현

② 각 범주 (기준) 만 얼마나 가까운지 유사한지 판단

↳ 데이터의 유사도 (similarity)


3.2 거리

'유사도'를 측정하는 척도는 매우 다양, 2 중 하나가 '거리 재기'

두 점 $A(a_1, a_2)$, $B(b_1, b_2)$ 사이의 거리

$$= \text{dist}(A, B) = \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2}$$

$\text{dist}(A, B)$ 작다 \rightarrow 유사하다, $\text{dist}(A, B)$ 크다 \rightarrow 유사하지 않다



$$\text{dist}(A, B) = \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2}$$

$$\text{dist}(A, C) = \sqrt{(a_1 - c_1)^2 + (a_2 - c_2)^2}$$

$$\text{dist}(A, B) < \text{dist}(A, C)$$

3.3 노름 (Norm)

R^n 벡터 a, b 벡터 $a = (a_1, a_2)$ 에 대하여 a 의 크기를 다음과 같이 나타내고, a 의 norm이라 한다.

$$\|a\| = \sqrt{a_1^2 + a_2^2} \quad (\text{벡터의 크기 계산: norm})$$

= 원점에서 점 $A(a_1, a_2)$ 에 이르는 거리

① $\|a\| \geq 0$

$\|a\| \iff a=0$

② $\|ka\| = k\|a\|$

③ $\|a+b\|$

$\leq \|a\| + \|b\|$

두 벡터 $a = (a_1, a_2)$, $b = (b_1, b_2)$ 에 대하여 $\|a-b\|$ 는 두 점 $A(a_1, a_2)$, $B(b_1, b_2)$ 사이의 거리가 되며, 다음이 성립한다.

$$\text{dist}(A, B) = \|a-b\| = \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2}$$

$a = (a_1, a_2, a_3)$

$b = (b_1, b_2, b_3)$

$$\|a\| = \sqrt{a_1^2 + a_2^2 + a_3^2}$$


$$\text{dist}(A, B) = \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2 + (a_3 - b_3)^2}$$

Additional
Section
+ Vector

Section 1.1 공학·수학에서의 벡터: n 차원공간

Def 스칼라 (Scalar) - 길이, 넓이, 질량, 온도
> 크기만 주어지면 완전하게 표시되는 양

Def 벡터 (Vector) - 속도, 위치운동량
> 크기뿐만 아니라 방향까지 지정해 양이면 불완전하게 표시되는 양
> 벡터는 크기나 방향 등을 갖는 유향선분
> 2, 3차원 공간의 벡터는 화살표를 표현 가능




Def Vector Sum / Scalar multiplication

벡터 x, y 와 스칼라 k 이 대하여, $x+y$ 와 $k \cdot x$ 를 다음과 같이 정의한다.

(1) $x+y$ 은 x, y 에 의하여 결정되는 평행사변형의 대각선으로 표시되는 벡터

(2) kx 는 ($k > 0$ 이면 x 와 방향이 같으면서 길이는 k 배 한 벡터
($k < 0$ 이면 x 와 방향이 반대이면서 길이는 $|k|$ 배 한 벡터
($k = 0$ 이면 $\|kx\| = 0$)



Def 평면벡터 vector in the plane
- 두 실수를 성분 (component) 으로 하는
벡터 $x = (x_1, x_2)$

Def 공간벡터 vector in space
- 세 실수를 성분으로 하는
벡터 $x = (x_1, x_2, x_3)$

Def 선형결합 (linear combination)

v_1, v_2, \dots, v_k 가 R^n 의 벡터이고, 계수 c_1, \dots, c_k 가 실수일 때

$$x = c_1 v_1 + c_2 v_2 + \dots + c_k v_k$$

이 형태를 v_1, v_2, \dots, v_k 의 선형결합 (linear combination) 이라 한다

* n 개 실수 성분 \rightarrow n 차원 벡터
 n -dimensional vector

3.4 노름(norm-크기, 거리)을 활용한 데이터 유사도 비교

(예제) $A(0, 1, -7, 1)$, $B(5, 2, -1, 3)$, $C(-2, 0, -4, 6)$
이 데이터에 B는 A와 C 중 어느 데이터와 더 가까운가?


$$\text{dist}(A, B) = \sqrt{(0-5)^2 + (1-2)^2 + (-7-1)^2 + (1-3)^2} = \sqrt{66}$$

$$\text{dist}(B, C) = \sqrt{(5-2)^2 + (2-0)^2 + (-1-4)^2 + (3-6)^2} = \sqrt{71}$$

\therefore B는 C보다 A에 더 가깝다.

3.5 사잇각을 활용한 데이터의 비교

‘유사도 = 거리가 가까움’ 아닌 ‘유사도 = 데이터 패턴(방향성)’이라면?



$$\boxed{a = (a_1, a_2) \text{ 와 } b = (b_1, b_2)}$$

→ 거리는 멀지만 방향성은 유사하다

→ 척도에 따라 매우 상반된 평가

3.6 코사인 유사도의 개념

사잇각 θ 은 벡터의 내적(inner product)으로부터 정의된다

→ 벡터 내적을 이용, θ 의 코사인 값으로 유사도 측정 = 코사인 유사도.

3.7 내적

두 벡터 $a(a_1, a_2)$, $b(b_1, b_2)$ 의 내적

$$a \cdot b = a_1 b_1 + a_2 b_2$$

두 벡터의 내적은 다음의 성질을 만족한다:

$$① a \cdot a = \|a\|^2 \geq 0, \quad a \cdot a = 0 \iff a = 0$$

$$② a \cdot b = b \cdot a \text{ (교환법칙)}$$

$$③ (a+b) \cdot c = a \cdot c + b \cdot c$$

$$④ (ka) \cdot b = a \cdot (kb) = k(a \cdot b)$$

Additional Section

Section 1.2 내적과 직교

for $x = (x_1, x_2, \dots, x_n)$ in \mathbb{R}^n

$$\|x\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

↳ norm, length, magnitude

def 내적 (Euclidean Inner Product, dot product)

\mathbb{R}^n 의 벡터 $x = (x_1, x_2, \dots, x_n)$, $y = (y_1, y_2, \dots, y_n)$ 에 대하여

실수 $x_1y_1 + x_2y_2 + \dots + x_ny_n$ 를 x 와 y 의 내적이라 하고 $x \cdot y$ 로 나타낸다.

* 코시-슈바르츠 부등식 (Cauchy-Schwarz inequality)

\mathbb{R}^n 임의의 벡터 x, y 에 대하여 다음 부등식이 성립한다.

$$|x \cdot y| \leq \|x\| \|y\|$$

(단, 등호는 x, y 중 하나만 다른 하나의 실수배일 때만 성립)

def 기호단위벡터

Standard unit vector

임의의 벡터 x 에 대하여,

$$u = \frac{1}{\|x\|} x$$

→ 단위벡터

\mathbb{R}^n 의 단위벡터들

다음 n 개의 벡터

$$e_1 = (1, 0, 0, \dots, 0)$$

$$e_2 = (0, 1, 0, \dots, 0)$$

$$\vdots$$

$$e_n = (0, 0, 0, \dots, 1)$$

→ 기호단위벡터

$$\begin{aligned} x &= (x_1, x_2, \dots, x_n) \\ &= x_1e_1 + x_2e_2 + \dots + x_n e_n \end{aligned}$$

def 두 벡터 사이의 각

\mathbb{R}^n 의 벡터 x, y 에 대하여

$$x \cdot y = \|x\| \|y\| \cos \theta \quad (0 \leq \theta \leq \pi)$$

인 θ 가 x 와 y 가 이루는 각 (angle, 사잇각)이라 한다.

* 직교와 평행

• $x \cdot y = 0$ 일 때 x 와 y 는 서로 직교 (orthogonal) 한다.

• 실수 k 에 대하여 $x = ky$ 인 경우 x 는 y 와 평행하다.

def 단위벡터, 직교벡터, 정규직교벡터

unit vector, orthogonal vector, orthonormal vector

\mathbb{R}^n 의 벡터 x 에 대하여 노름이 1인 벡터, 즉 $\|x\| = 1$ 인 벡터 = 단위벡터

\mathbb{R}^n 의 벡터 x, y 가 직교 $\rightarrow x, y$ 는 직교 (orthogonal)

\mathbb{R}^n 의 벡터 x, y 가 직교하며 각각 단위벡터 $\rightarrow x, y$ 는 정규직교 (orthonormal)


def 벡터에 대한 삼각부등식

$$\mathbb{R}^n$$
의 벡터 x, y 에 대하여 $\|x+y\| \leq \|x\| + \|y\|$ (단, 등호는 $y=kx, k \geq 0$ 일 때만)

3.8 사잇각

벡터의 내적은 두 벡터가 이루는 사잇각과 관련이 있다.

<피타고라스 정리 이용>



$$\begin{aligned} c^2 &= (a \sin \theta)^2 + (b - a \cos \theta)^2 \\ &= a^2 + b^2 - 2ab \cos \theta \end{aligned}$$

↓ 벡터를 이용하여 표현

1

$$\|a - b\|^2 = \|a\|^2 + \|b\|^2 - 2\|a\|\|b\|\cos \theta$$

↓ 내적의 정의와 성질에 의해

두 식을 비교하면
 $a \cdot b = \|a\|\|b\|\cos \theta$

$$\cos \theta = \frac{a \cdot b}{\|a\|\|b\|}$$

($0 \leq \theta \leq \pi$)

$$\|a - b\|^2 = (a - b) \cdot (a - b)$$

$$= a \cdot a - a \cdot b - b \cdot a + b \cdot b$$

$$= \|a\|^2 + \|b\|^2 - 2(a \cdot b)$$

2

3.9 코사인 유사도의 계산

cosine similarity

→ 코사인 값이 크면, 사잇각은 작아지고, 유사도는 높아진다.

$$\cos \theta = \frac{a \cdot b}{\|a\|\|b\|} = \left[\left(\frac{a}{\|a\|} \right) \cdot \left(\frac{b}{\|b\|} \right) \right] \quad \text{for } a = (a_1, a_2, \dots, a_n)$$

$b = (b_1, b_2, \dots, b_n)$

$a, b \in \mathbb{R}^n$

$0 \leq \theta \leq \pi$

66 $\frac{a}{\|a\|}$ or $\frac{b}{\|b\|}$ 는 크기(norm)가 항상 1인 단위벡터(unit vector)

→ 코사인 유사도는 크기/차이는 무시하고 데이터의 패턴(방향성)만 고려

→ 코사인 값 \propto 코사인 유사도

